

CHURN ANALYSE



Forfattere:

Line A. Adolph, Maria B. A. Hitz, Maria Cristiana Maxim, Martin E. Bindner, Abdikadir A. M. H. Omar

2. interne eksamensprojekt

Vejleder: Simon Bjerrum Eilersen

Dato: 9. maj 2025

Antal tegn: xx.xxx + Shiny App

Indholdsfortegnelse

1	Resumé	4
2	Indledning	4
3	Problemstilling	5
4	Problemformulering	5
4.1	Underspørgsmål	5
5	Afgrænsning	6
5.1	AI-chatbots og anvendelse af ChatGPT	6
5.2	Datagrundlag	7
5.3	Modellens omfang og valg af algoritmer	7
5.4	Systemintegration	7
5.5	Juridiske og etiske vurderinger	7
6	Definitioner	8
7	Analyse	9
7.1	Dataforståelse og fordeling	9
7.2	Egenskaber ved virksomheder med høj churn	9
7.3	Feature engineering	13
7.4	Modelperformance	14
7.5	Perspektiv: Modellering af churn over tid	15
7.6	Variable importance og indsigt	15
7.7	Fordeling af churn-risiko	16
8	Juridiske og etiske overvejelser	17
8.1	Juridiske og etiske forhold i churn-projektet for Business Viborg	17
8.2	Behandlingsgrundlag	18
8.3	Personoplysninger og dataminimering	18
8.4	Oplysningspligt og transparens	19

8.5	Pseudonymisering og identifikationsrisici	19
8.6	Etiske overvejelser og ansvarlig dataanvendelse	19
8.7	Må Business Viborg beholde data på udmeldte medlemmer	20
8.8	Delonklusion	21
9	Anbefaling	21
10	Konklusion	22
11	Literaturliste	24
12	Bilagsoversigt	25

1 Resumé

Business Viborg arbejder for at skabe optimale rammer for erhvervslivet i Viborg Kommune og har en ambition om at nå 700 medlemmer i 2025. Medlemsafgang truer imidlertid både organisationens økonomiske fundament og dens rolle som erhvervspolitisk talerør. For at imødekomme denne udfordring er der i dette projekt udviklet en datadrevet prototype, der forudsiger churn og identificerer centrale risikofaktorer på medlemsniveau.

Løsningen kombinerer brugervenlig formidling med avanceret maskinlæring i et R-baseret workflow. Seks modeller blev afprøvet, hvor Random Forest blev valgt som slutmodel på baggrund af gennemsigthed og forklaringskraft. Feature engineering inddrager bl.a. kontaktfrekvens, eventdeltagelse og modtaget erhvervshjælp.

Modellen er operationaliseret i et interaktivt dashboard, som understøtter medlemskonsulenternes op søgende arbejde. Projektet er udviklet med respekt for GDPR og dataetik og illustrerer, hvordan en lokal medlemsorganisation med begrænsede ressourcer kan anvende data strategisk og ansvarligt til at styrke fastholdelsen og engagementet blandt sine medlemmer.

2 Indledning

Business Viborg er en medlemsorganisation, der arbejder målrettet for at skabe optimale vilkår for erhvervslivet i Viborg Kommune. Med over 600 medlemsvirksomheder udgør organisationen en væsentlig aktør i det lokale erhvervsøkosystem – både som netværksfacilitator, vidensformidler og politisk interessevaretager. Ifølge chefkonsulent Michael Freundlich er ambitionen at nå 700 medlemmer og en omsætning på 2,9 mio. kr. i 2025.

Men når virksomheder forlader organisationen, reduceres ikke blot indtægtsgrundlaget – også Business Viborgs netværkskapital og politiske legitimitet svækkes. Derfor er det afgørende at få indsigt i, hvilke faktorer der øger risikoen for udmeldelse, og hvordan man kan arbejde proaktivt med medlemsfastholdelse.

I dette projekt udvikles der en datadrevet løsning, der kombinerer teknisk analyse med brugervenlig indsigt og som respekterer både juridiske og etiske rammer. Målet er at styrke medlemskonsulenternes beslutningsgrundlag og understøtte en mere effektiv og målrettet medlemspleje.

3 Problemstilling

Business Viborg er registreret under branchekoden 26104793, og arbejder målrettet for at skabe optimale rammer for erhvervslivet i Viborg Kommune. Som en medlemsorganisation med over 600 virksomheder i ryggen, er relationerne til medlemskredsen helt afgørende, både for at dele viden, styrke netværk og skabe lokal vækst. I forbindelse med præsentationen af Business Viborg udtalte chefkonsulent Michael Freundlich: "Vores mål for 2025 er at nå 700 medlemmer og en omsætning på 2,9 mio. kr."

Men når virksomheder melder sig ud, mister Business Viborg ikke kun en indtægt, men også værdifulde forbindelser, politisk legitimitet og mulighed for at gøre en forskel for erhvervslivet i området. For at handle proaktivt ønsker Business Viborg at få bedre indsigt i, hvad der driver churn og hvem der er i risikozonen.

Derfor skal der udvikles et datadrevet værktøj, som kombinerer teknisk analyse med brugervenlig indsigt. Et værktøj, der gør det muligt for både medlemskonsulenter og ledelse at træffe kloge beslutninger og handle i tide med respekt for både dataetik og jura.

4 Problemformulering

Hvordan kan Business Viborg analysere og anvende medlemsdata til at udvikle et beslutningsunderstøttende dashboard, der forudsiger churn og forklarer centrale risikofaktorer – baseret på relevante maskinlæringsmetoder og med inddragelse af etiske og juridiske overvejelser?

4.1 Underspørgsmål

Eksplorativ analyse (EDA)

Beskriv hvilke mønstre og karakteristika kendetegner de virksomheder, der forlader Business Viborg?

Modelvalg og performance

Hvordan kan forskellige machine learning-modeller anvendes til at forudsige churn i Business Viborgs kontekst, og hvilke modeller er mest velegnede?

Datavisualisering

Hvordan kan resultater og churn-indsigter formidles via et brugervenligt dashboard, som understøtter daglig opsøgende indsats for medlemskonsulenter og ledelse?

Etik og jura

Hvilke juridiske krav (fx GDPR) og etiske overvejelser bør indgå i udviklingen og brugen af et churn-forudsigelsesværktøj baseret på medlemsdata?

5 Afgrænsning

I udviklingen af en datadrevet churn-model for Business Viborg er det nødvendigt at foretage en række metodiske og praktiske afgrænsninger for at sikre projektets gennemførlighed og fokus. Følgende underafsnit præciserer, hvordan projektets omfang er afgrænset i forhold til teknologisk anvendelse, datagrundlag, modeller, systemintegration og juridiske vurderinger.

5.1 AI-chatbots og anvendelse af ChatGPT

ChatGPT 4.0 har været anvendt som et understøttende værktøj i forbindelse med idéudvikling, sproglig formulering og grammatisk korrektur. Modellen har alene fungeret som et supplement i arbejdet med tekstbaserede opgaver og har ikke erstattet selvstændig analyse, faglig vurdering eller besvarelse af projektets problemformulering. Chatbotten er således ikke anvendt til at generere indhold i den analytiske eller metodiske del af projektet.

5.2 Datagrundlag

Projektet baserer sig udelukkende på det datasæt, der er stillet til rådighed af Business Viborg. Datasættet indeholder oplysninger om medlemskab, virksomhedsdemografi, branchetilknytning, kontaktaktivitet, eventdeltagelse samt ydet rådgivning. Alle data er pseudonymiserede og begrænset til et afgrænset tidsrum. Dette kan påvirke modellens generaliserbarhed over tid og dens evne til at indfange nyere tendenser i medlemsadfærd.

5.3 Modellens omfang og valg af algoritmer

Formålet med projektet er at udvikle en forklarlig og anvendelig prototype frem for en produktionsklar løsning. Der er derfor ikke foretaget omfattende hyperparameter-tuning for alle modeller. Seks modeller er testet – herunder Support Vector Machine, Random Forest og XGBoost – og performance er evalueret på baggrund af F1-score og AUC som de primære metrikker. Fokus har været på at finde en balance mellem prædiktiv nøjagtighed og forklaringskraft.

5.4 Systemintegration

Den udviklede løsning er implementeret som en webbaseret prototype i R og er ikke integreret med Business Viborgs interne systemer, såsom CRM- eller medlemsdatabaser. Modellen kan tilgås og anvendes lokalt gennem RStudio Cloud eller ved afvikling på en dedikeret server, men kræver manuel opdatering af data. Fremtidig integration og automatisering er oplagte skridt i en potentiel videreudvikling.

5.5 Juridiske og etiske vurderinger

Projektet indeholder en overordnet vurdering af de juridiske og etiske rammer med fokus på dataminimering, transparens og behandlingsgrundlag i henhold til GDPR. Der er ikke foretaget en fuld juridisk gennemgang, og tekniske løsninger som adgangsstyring, kryptering og samtykkehåndtering er ikke implementeret i prototypen. Disse aspekter betragtes som en integreret del af en eventuel implementeringsfase og bør afklares i samarbejde med relevante juridiske rådgivere og systemansvarlige.

6 Definitioner

I dette afsnit defineres centrale begreber og forkortelser anvendt gennem rapporten:

Churn: Når en virksomhed ophører med sit medlemskab i Business Viborg. I datasættet angives dette som en binær variabel, hvor 1 betyder churn og 0 betyder fortsat medlemskab.

Churn-model: En prædiktiv model, der estimerer sandsynligheden for, at en virksomhed cherner. Den er baseret på historiske medlemsdata og konstruerede forklaringsvariable.

Feature Engineering: Fremstilling af nye forklarende variable fra eksisterende data, som styrker modellens evne til at forudsige churn. Eksempler inkluderer medlemsanciennitet, kontaktaktivitet og deltagelse i arrangementer.

MeetingLength: Længden af det seneste dokumenterede møde med en virksomhed, målt i minutter. Bruges som indikator for relationens styrke.

har_haft_kontakt: En binær indikator for, om virksomheden har haft kontakt med Business Viborg (f.eks. møder, telefonopkald eller rådgivning).

deltaget_i_event: Binær variabel der angiver, om virksomheden har deltaget i mindst ét event i analyseperioden.

hjælp_kategori: En kategorisk variabel, der angiver typen af erhvervsfaglig støtte virksomheden har modtaget. Kategorierne er fx Strategi Udvikling, Organisation og Ledelse, Jura og Struktur m.fl.

medlem_antal_år: Antal år virksomheden har været medlem, beregnet som forskellen mellem analysedato og oprettelsesdato.

Machine Learning (ML): En metode til at bygge modeller, der kan lære mønstre i data og forudsige fremtidige hændelser. I projektet er ML anvendt til churn-forudsigelse.

Random Forest: En ML-algoritme, der kombinerer mange beslutningstræer for at skabe en robust og forklarlig model. Valgt som slutmodel i projektet.

ROC AUC: Et mål for modellens evne til at adskille churnere og ikke-churnere. En værdi tæt på 1 indikerer høj prædiktiv nøjagtighed.

F_meas (F1-score): Et samlet præstationsmål, som balancerer præcision og recall – særligt velegnet ved skæve datasæt.

Dashboard: Et interaktivt visualiseringsværktøj, der præsenterer churn-risici og medlemsindsigter på en overskuelig måde til brug i den daglige medlemspleje.

GDPR: EU's databeskyttelsesforordning. Projektet tager højde for centrale principper som dataminimering, transparens og legitimt behandlingsgrundlag.

7 Analyse

7.1 Dataforståelse og fordeling

Analysen tager udgangspunkt i et datasæt bestående af 2.966 medlemsvirksomheder tilknyttet Business Viborg, som har et selvstændigt P-nummer. Datasættet afspejler en betydelig variation med hensyn til virksomhedsstørrelse, branchetilhørsforhold og interaktionsniveau med organisationen.

En indledende fordeling afslører, at virksomheder uden dokumenteret kontakt eller deltagelse i arrangementer har markant højere churn-rate. Denne observation antyder, at fraværet af kontakt og engagement kan være centrale indikatorer for medlemsophør.

7.2 Egenskaber ved virksomheder med høj churn

For bedre at forstå hvordan forskellige former for engagement påvirker medlemsstatus, har vi kombineret to centrale variabler: kontakt med Business Viborg og deltagelse i events. Dette giver fire grupper, som varierer i deres relation til organisationen. Figuren nedenfor viser tydeligt, hvordan virksomheder med både kontakt og eventdeltagelse i langt højere grad fastholdes som medlemmer, mens fravær af begge faktorer er stærkt forbundet med churn.




Figure 1: Fravær af begge faktorer er tæt forbundet med udmeldelse, mens dobbelt engagement viser stærk fastholdelse.

Virksomheder med begrænset kontakt til organisationen, lav deltagelse i arrangementer og uden dokumenteret interaktion har generelt en markant højere risiko for at opsige deres medlemskab. Dette underbygges af figuren nedenfor, der viser de fem postnumre med den højeste gennemsnitlige churn-risiko. Her ses, at geografiske områder med lav tilknytning til det centrale område (8800 Viborg) udviser særlig høj churn-sandsynlighed.




Figure 2: Geografisk afstand fra Viborgs centrum ser ud til at spille en rolle i udmeldelsestendens. 9620 Aalestrup, 7800 Skive, 7850 Stoholm, 7470 Karup, 8831 Løgstrup

Også på brancheniveau er der tydelige forskelle. Nogle brancher er kendetegnet ved begrænset interaktion med organisationen og har derfor en højere sandsynlighed for medlemsophør. Figuren herunder visualiserer de fem brancher med den højeste gennemsnitlige churn-risiko, hvilket bekræfter tendensen.




Figure 3: Brancher med lav netværkssværdi og specialiserede ydelser udviser generelt højere risiko for medlemsophør.

Omvendt findes der brancher, hvor medlemmerne i langt højere grad fastholdes. Disse brancher har ofte en mere stabil tilknytning og deltager aktivt i organisationens tilbud. Den følgende visualisering viser de fem brancher, hvor medlemmerne i størst omfang forbliver tilknyttet – hvilket indikerer, at der her eksisterer en stærkere relation og et større udbytte af medlemskabet.




Figure 4: Branchenes høje fastholdelse kan skyldes stærkere relationer og oplevet værdi af netværket.

I de fem brancher hvor churnrisikoen er lille, er antallet af virksomheder højt. Dette kunne understøtte teorien om at netværkswærdi har høj prioritet, blandt dem der er medlemmer af Business Viborg.

7.3 Feature engineering

På baggrund af ovenstående mønstre blev der konstrueret nye forklarende variabler for at styrke modellernes prædiktioner. De mest centrale inkluderer:

- medlem_antal_år: længden af medlemskab målt i år
- har_haft_kontakt: binær indikator for, om der har været nogen form for kontakt
- deltaget_i_event: binær indikator for eventdeltagelse

Disse variabler blev udledt på baggrund af domæneviden og eksplorativ analyse, og bidrog væsentligt til forbedret modelperformance.

7.4 Modelperformance

Seks machine learning modeller blev afprøvet: Support Vector Machine (SVM), XGBoost, Random Forest, logistisk regression, K-nearest Neighbors (KNN) og Naive Bayes.




Figure 5: Farveintensitet viser performance – mørkere felter angiver højere score. Random Forest og XGBoost scorer generelt højt, mens Naive Bayes udviser lav F1-score.

På trods af XGBoost gode resultater blev Random Forest valgt som slutmodel. Dette skyldes modellens kombination af prædiktiv styrke og modelgennemsigtighed, hvilket gør den mere anvendelig i en praktisk kontekst. XGBoost blev fravalgt grundet behovet for yderligere parameteroptimering, som ikke var formålstjenligt inden for projektets rammer. Vi valgte den mest simple af de to modeller, da deres metrikker lå meget tæt.




Figure 6: Lineplot over modelperformance. Random Forest og XGBoost opnår høj score på alle tre metrikker, hvilket underbygger deres styrke som robuste og præcise modeller.

7.5 Perspektiv: Modellering af churn over tid

Da vores datasæt ikke indeholdt tidsstempler for, hvornår virksomheder præcist meldte sig ud, har vi arbejdet med churn som en binær klassifikation. Hvis disse oplysninger forelå, ville det være oplagt at anvende time-to-event-modeller som fx Cox proportional hazards-model. Disse modeller gør det muligt at estimere, ikke blot om churn indtræffer, men også hvornår – hvilket kan styrke den opsøgende indsats og skabe bedre timing i medlemspleje. Det vil samtidig muliggøre en dynamisk forståelse af churn-risiko over tid og dermed forbedre prioriteringen af indsatser.

7.6 Variable importance og indsigt

Ved hjælp af vip()-pakken blev de mest betydningsfulde variable i Random Forest-modellen identificeret. De fem vigtigste prædiktorer var:

- deltaget_i_event_Ja
- deltaget_i_event_Nej
- MeetinLenght

- Employees
- medlem_antal_år

Disse variable udgør tilsammen et stærkt grundlag for at forstå churn-mekanismer i Business Viborgs medlemsbase og bekræfter den eksplorative analyses fund.




Figure 7: Eventdeltagelse, mødelængde, antal ansatte og medlem_antal_år er blandt de mest betydningsfulde prædiktorer for churn.

7.7 Fordeling af churn-risiko

For at operationalisere modellen i medlemsarbejdet er alle aktive virksomheder blevet klassificeret i fire risikokategorier baseret på deres sandsynlighed for churn. Som det fremgår af figuren nedenfor, har hovedparten af medlemsbasen en lav eller minimal risiko for udmeldelse, mens en mindre andel er vurderet til at være i moderat eller høj risiko. Denne fordeling giver medlemskonsulenterne et konkret udgangspunkt for at prioritere deres indsats og målrette dialogen mod virksomheder i risikozonen.




Figure 8: Fordeling af churn-risiko blandt aktive medlemmer baseret på modelprediktioner. Kategorierne “høj risiko” og “moderat risiko” rummer 38 virksomheder. De udgør et vigtigt proaktivt fokuspunkt.

8 Juridiske og etiske overvejelser

8.1 Juridiske og etiske forhold i churn-projektet for Business Viborg

I forbindelse med udviklingen af en datadrevet løsning til forudsigelse af medlems-churn hos Business Viborg er det essentielt, at både juridiske og etiske hensyn bliver nøje overvejet og integreret i hele udviklingsprocessen. Den teknologiske og analytiske dimension af projektet må ikke stå alene, men skal suppleres af en bevidsthed om datasikkerhed, individets rettigheder og ansvarlig brug af data. Da løsningen tager udgangspunkt i oplysninger om organisationens medlemmer, der potentielt kan knyttes til identificerbare personer, er databehandlingen omfattet af EU’s Databeskyttelsesforordning (GDPR). Dette gælder, uanset om data fremstår pseudonymiserede for os som analytikere, da Business Viborg internt kan koble data til konkrete virksomheder eller kontaktpersoner. Formålet med dette afsnit er derfor at belyse de centrale juridiske forpligtelser samt de etiske retningslinjer, som Business Viborg bør overholde i forbindelse med udviklingen og implementeringen af churn-modellen.

8.2 Behandlingsgrundlag

Et fundamentalt krav i GDPR er, at al behandling af personoplysninger skal have et lovligt behandlingsgrundlag. Business Viborgs databehandling relaterer sig til almindelige personoplysninger såsom virksomhedsnavne, kontaktoplysninger, mødedeltagelse og interaktionshistorik. Det er derfor nødvendigt at vurdere, hvilket hjemmelsgrundlag der gør det lovligt at anvende disse data i en churn-model. Ifølge artikel 6 i GDPR kan behandlingen enten baseres på samtykke fra medlemmerne (art. 6, stk. 1, litra a) eller på organisationens legitime interesser (art. 6, stk. 1, litra f). I denne kontekst vurderes det, at Business Viborg primært bør benytte den legitime interesse som behandlingsgrundlag, da organisationens formål – at forbedre medlemsservice, understøtte fastholdelse og sikre et bæredygtigt erhvervsfællesskab – er både sagligt, proportionalt og foreneligt med medlemmernes forventninger. Det er dog vigtigt at bemærke, at hvis data senere anvendes til andre formål, f.eks. målrettet markedsføring eller automatiseret profilering, kan det være nødvendigt at genoverveje behandlingsgrundlaget, herunder at indhente eksplicit samtykke.

8.3 Personoplysninger og dataminimering

Analyserne tager udgangspunkt i almindelige personoplysninger, som ikke i sig selv er følsomme, men som i kombination med andre oplysninger stadig udgør personoplysninger i GDPR-forstand. Eksempler kan være data om deltagelse i arrangementer, mødeaktivitet eller medlemskabets varighed. For at overholde principperne om dataminimering og formålsbegrænsning (jf. GDPR art. 5), skal Business Viborg sikre, at der kun behandles data, som er nødvendige og relevante i forhold til det definerede formål – nemlig at kunne identificere virksomheder i risiko for udmeldelse. Alle unødvendige oplysninger bør fjernes eller anonymiseres, og det samlede datasæt skal reduceres til det minimum, der kræves for at modellere churn med høj præcision. Derudover skal der være dokumentation for, hvordan og hvorfor de valgte variabler indgår i modellen. Denne dokumentation skal kunne anvendes til intern kontrol og overfor Datatilsynet, hvis der føres tilsyn.

8.4 Oplysningspligt og transparens

Business Viborg har i henhold til GDPR artikel 13 og 14 en klar oplysningspligt over for de registrerede medlemmer. Det betyder, at medlemmerne skal informeres om, at deres data indgår i analyser, hvad formålet med analysen er, hvilke rettigheder de har, og hvordan de kan kontakte organisationen for spørgsmål eller indsigelser. Oplysningen bør være let tilgængelig og formuleret i et sprog, der er forståeligt for ikke-specialister. Ideelt set bør informationen formidles både via organisationens privatlivspolitik og i forbindelse med medlemskommunikation – f.eks. i velkomstmateriale eller nyhedsbreve. Transparens er i denne sammenhæng ikke blot et juridisk krav, men også et middel til at styrke medlemmernes tillid til Business Viborgs databrug.

8.5 Pseudonymisering og identifikationsrisici

Selvom datasættet, som analysen baseres på, er pseudonymiseret for dataanalytikerne, betyder det ikke, at oplysningerne er anonyme i GDPR-forstand. Business Viborgs medarbejdere har adgang til nøgleoplysninger såsom medlemsnummer, virksomhedsnavn eller kontaktpersoner, som gør det muligt at identificere de registrerede. Dette understreger, at databehandlingen fortsat er omfattet af alle GDPR-krav. Der skal derfor træffes passende forholdsregler for at sikre, at oplysningerne ikke anvendes til andre formål uden nyt behandlingsgrundlag og ikke utilsigtet afslører følsom information om specifikke virksomheder. Datasikkerhed og organisatorisk ansvar Business Viborg er som dataansvarlig forpligtet til at beskytte personoplysninger mod uautoriseret adgang, tab, ændring eller misbrug. I henhold til artikel 24 og 32 i GDPR skal organisationen iværksætte både tekniske og organisatoriske sikkerhedsforanstaltninger. Det inkluderer brug af adgangsstyring, kryptering, logning af datatilgange, opdaterede sikkerhedspolitikker og uddannelse af personale i datasikkerhed. Derudover skal der foreligge databehandleraftaler, hvis eksterne samarbejdspartnere inddrages i projektet. Manglende sikkerhed kan ikke alene få juridiske konsekvenser, men også underminere den tillid, som projektet skal baseres på.

8.6 Ethiske overvejelser og ansvarlig dataanvendelse

Udover den juridiske ramme bør Business Viborg også forholde sig aktivt til dataetik og samfundsansvar. Ifølge anbefalinger fra bl.a. Dataetisk Råd handler ansvarlig dataanvendelse om at sætte mennesket i

centrum, sikre gennemsigtighed og undgå skævvridning eller diskrimination. Anvendelsen af en churn-model må ikke resultere i, at bestemte virksomheder eller grupper automatisk vurderes som mindre værdifulde baseret på statistiske mønstre, som ikke er sagligt begrundede. Der skal derfor tages højde for fairness og risikoen for bias – både i datasættets sammensætning og i de variable, der anvendes i modellen. Transparens er også afgørende her: medarbejdere skal kunne forstå og forklare modellens logik og resultater. En “black box”-model, som ikke kan forklares, kan føre til uforståelige eller urimelige beslutninger, hvilket ikke er foreneligt med en ansvarlig og tillidsvækkende medlemsorganisation. Ledelsen i Business Viborg har desuden et særligt ansvar for at sikre, at modellen anvendes i overensstemmelse med organisationens værdier. Det anbefales derfor, at der formuleres en dataetik-politik, som dækker ansvar, kontrol og kommunikation i relation til anvendelsen af churn-modellen. Politikken bør revideres løbende i takt med, at modellen og databrug udvikles.

8.7 Må Business Viborg beholde data på udmeldte medlemmer

Ifølge GDPR artikel 5, stk. 1, litra e, må personoplysninger ikke opbevares længere end nødvendigt til det formål, de er indsamlet til. Når et medlem melder sig ud, er det normale formål – f.eks. kommunikation, arrangementer eller medlemsservice – ikke længere aktuelt.

Men der kan være lovlige grunde til at opbevare dem i en periode Business Viborg må godt gemme data i en vis periode efter udmeldelse, hvis de har et sagligt og dokumenteret formål, f.eks.:

- Bogføring og regnskab – fx fakturaer, betalinger osv. må gerne opbevares i op til 5 år (jf. Bogføringsloven).
- Statistisk analyse – men kun hvis data anonymiseres eller pseudonymiseres, så det ikke længere er muligt at identificere personen uden ekstra oplysninger.
- Retligt forsvar – hvis der er risiko for tvister eller krav, kan man argumentere for at opbevare data i en periode, typisk op til forældelsesfristen (som ofte er 3 år i civile sager).

De må ikke fortsætte med at bruge tidligere medlemmers data til markedsføring og ikke opbevare data “bare for en sikkerheds skyld” uden formål og dokumentation.

CVR-numre tilknyttet enkeltmandsvirksomheder betragtes som personoplysninger, da de kan føres direkte tilbage til en fysisk person – virksomhedens ejer. Selvom disse oplysninger identificerer en per-

son, klassificeres de ikke som følsomme oplysninger i henhold til GDPR's artikel 9, da de ikke afslører forhold som helbred, politisk overbevisning eller religiøs tilhørsforhold. CVR-oplysninger er desuden offentligt tilgængelige og indgår derfor under almindelige personoplysninger, som stadig skal behandles i overensstemmelse med GDPR's generelle principper.

8.8 Delonklusion

Sammenfattende vurderes det, at Business Viborgs churn-projekt kan gennemføres i overensstemmelse med GDPR og etiske retningslinjer, forudsat at visse betingelser overholdes. Der skal foreligge et klart og dokumenteret behandlingsgrundlag, medlemmerne skal informeres tydeligt og rettidigt, og datasættet skal reduceres til relevante oplysninger i henhold til formålet. Desuden skal organisationen sikre passende tekniske og organisatoriske sikkerhedsforanstaltninger og være opmærksom på, at data fortsat er personhenførbare, selvom de fremstår pseudonymiserede. Afslutningsvis bør Business Viborg betragte dette projekt som et skridt mod mere datadrevet medlemsservice – men også som en mulighed for at styrke sin rolle som en ansvarlig og gennemsigtig aktør i det lokale erhvervsliv. Det forudsætter, at juridiske forpligtelser og dataetiske principper ikke ses som forhindringer, men som en integreret del af en moderne og tillidsbaseret organisation.

9 Anbefaling

På baggrund af analysen anbefales det, at Business Viborg anvender den udviklede churn-model som et beslutningsunderstøttende værktøj i det opsøgende medlemsarbejde. Modellen kan identificere virksomheder med høj risiko for udmeldelse og derved muliggøre en mere målrettet og proaktiv indsats fra medlemskonsulenterne. Det foreslås, at den udviklede Shiny app indgår som fast element i konsulenterne arbejdsrutiner og prioritering af medlemmer.

- Medlemspleje prioriteres over for virksomheder uden kontakt, eventdeltagelse eller modtaget hjælp, da disse faktorer er stærkt associeret med churn. Særligt events er relevante for at bibeholde medlemmerne. De har allerede mange events, men det kunne anbefales at lave flere skræddersyede events, så man sænker risikoen for churn på samtlige medlemmer.

- Løbende opdatering af modellen sikres ved at integrere churn-værktøjet i Business Viborgs CRM eller medlemsdatabase, så nye data automatisk indgår i fremtidige analyser.
- Etisk og transparent kommunikation om brugen af data indgår i medlemsdialogen for at styrke tilliden og sikre overholdelse af GDPR.

10 Konklusion

Projektet har vist, hvordan Business Viborg med et afgrænset datagrundlag og begrænsede ressourcer kan anvende machine learning som et konkret værktøj til medlemsfastholdelse. Gennem analyse af 2.966 medlemsvirksomheder og systematisk afprøvning af seks modeller blev der udviklet en forklarlig Random Forest-model med stærke prædiktive egenskaber ($F1 = 0,71$, $AUC = 0,86$). Modellen er operationaliseret i et interaktivt dashboard, der giver medlemskonsulenterne og ledelse et datadrevet grundlag for at prioritere og målrette deres opsøgende indsats.

Resultaterne peger entydigt på, at fravær af kontakt, manglende eventdeltagelse og manglende erhvervshjælp er tæt knyttet til udmeldelse. Samtidig viser analysen, at en langvarig relation og relationel dybde – målt gennem fx mødelængde – hænger tæt sammen med fastholdelse. Denne indsigt skaber en direkte kobling mellem data og daglig praksis i medlemsarbejdet. Den største faktor er deltagelse i events og der kan med fordel udvikles skræddersyede events, der skaber værdi og dermed fastholdelse af flere medlemmer.

Modellen er udviklet med udgangspunkt i GDPR og principper om ansvarlig dataanvendelse. Det understreger, at datadrevne løsninger godt kan gå hånd i hånd med transparens, etik og tillid. Der er taget højde for både behandlingsgrundlag, oplysningspligt og identifikationsrisici – og løsningen kan derfor fungere som en ansvarlig prototype, der med de rette tekniske og organisatoriske rammer kan bringes i anvendelse.

Et oplagt næste skridt er at inddrage tidsstempler for udmeldelse. Det vil muliggøre brugen af survival analysis, som ikke blot estimerer risikoen for churn, men også hvornår den mest sandsynligt vil indtræffe. Dette vil give Business Viborg mulighed for at arbejde endnu mere præcist og rettidigt med medlemspleje og beslutningsunderstøttelse.

Samlet set besvarer projektet sin problemformulering ved at kombinere teknisk analyse, brugervenlig formidling og etisk ansvarlighed. Det peger samtidig frem mod en bredere anvendelse af datadrevne beslutningsværktøjer i medlemsorganisationer, der ønsker at arbejde strategisk og relationsbaseret – uden at give køb på tillid, menneskelig dømmekraft og lokal forankring.

11 Literaturliste

AI

OpenAI. (2025). ChatGPT (version 4.0). Hentet fra <https://chatgpt.com/>

Bøger

Wickham, H., Çetinkaya-Rundel, M., & Grolemund, G. (2023). R for Data Science (2. udg.). O'Reilly Media. Hentet fra <https://r4ds.hadley.nz/>

Wickham, H. (2016). ggplot2: Elegant Graphics for Data Analysis (2. udg.). Springer. Hentet fra <https://ggplot2-book.org/>

Kuhn, M., & Silge, J. (2022). Tidy Modeling with R. O'Reilly Media. Hentet fra <https://www.tmwr.org/>

WWW-dokumenter

Europa-Parlamentet og Rådet. (2016). Forordning (EU) 2016/679 – Generel forordning om databeskyttelse (GDPR). Hentet fra <https://eur-lex.europa.eu/legal-content/DA/TXT/?uri=CELEX%3A32016R0679>

Erhvervsstyrelsen. (2025). Vejledning til bogføringsloven. Hentet fra <https://erhvervsstyrelsen.dk/vejledning-bogfoeringsloven>

Dataetisk Råd. (2025). Officielt websted for Dataetisk Råd. Hentet fra <https://dataetiskraad.dk/>

12 Bilagsoversigt

Anvendt i forbindelse med udarbejdelse og forståelse af datasættet:

- Bilag 1: Fordeling af medlemmer hos Business Viborg (filnavn: EDA_1_fordeling_medlemmer.png)
- Bilag 2: Antal år som medlem (boksplot) (filnavn: EDA_2_antal_år_medlem.png)
- Bilag 3: Fordeling af antal år som medlem (filnavn: EDA_3_fordeling_antal_år.png)
- Bilag 4: Eventdeltagelse blandt aktive medlemmer (filnavn: EDA_4_eventdeltagelse.png)
- Bilag 5: Hjælpetyper hos aktive medlemmer der ikke deltager i events (filnavn: EDA_6_deltager_ikke_events.png)
- Bilag 6: Hjælpetyper hos aktive medlemmer der deltager i events (filnavn: EDA_6_1_deltager_i_events.png)
- Bilag 7: Branchefordeling blandt aktive medlemmer (filnavn: EDA_7_branchefordeling.png)
- Bilag 8: Eventdeltagelse fordelt på branche (filnavn: EDA_8_eventdeltagelse_branche.png)
- Bilag 9: Hjælpekategorier fordelt på branche (filnavn: EDA_9_hjælpekategorier_branche.png)
- Bilag 10: Eventdeltagelse pr. postnummer (filnavn: EDA_10_eventdeltagelse_postnummer.png)
- Bilag 11: Gennemsnitlig mødelængde pr. branche (filnavn: EDA_11_mødelængde.png)
- Bilag 12: Mødelængde vs. eventdeltagelse (filnavn: EDA_12_mødelængde_eventdeltagelse.png)
- Bilag 13: Mødelængde vs. medlemsstatus (filnavn: EDA_13_mødelængde_medlemsstatus.png)
- Bilag 14: Fordeling af mødelængder (filnavn: EDA_14_fordeling_mødelængder.png)
- Bilag 15: Korrelationsmatrix for numeriske variable (filnavn: EDA_15_korrelationsmatrix.png)

Modelvisualiseringer

Anvendt i forbindelse med udvikling og evaluering af maskinlæringsmodeller:

- Bilag 16: Model performance (Accuracy, F1 og ROC AUC) (filnavn: 1_model_performance.png)
- Bilag 17: Top 10 vigtigste variabler pr. model (filnavn: 4_top_10_variabler_pr_model.png)

```

# -----
# 1. Load data
# -----

# Indlæser alle nødvendige datasæt
meetings <- readRDS("data/meetings.rds")
events <- readRDS("data/events.rds")
event_participants <- readRDS("data/event_participants.rds")
company_contacts <- readRDS("data/company_contacts.rds")
all_contact <- readRDS("data/all_contact.rds")
all_companies <- readRDS("data/all_companies.rds")
old_projects <- readRDS("data/old_projects.rds")

# -----

# 2. Merge datasets
# -----

# -----

# 2.1: Fjern dubletter og behold første registrering pr. virksomhed
# -----

meetings_unique <- meetings |>
  group_by(CompanyId) |>
  summarise(across(everything(), first))    # Første møde pr. virksomhed

events_unique <- events |>
  group_by(Cvr) |>
  summarise(across(everything(), first))    # Første event pr. virksomhed

event_participants_unique <- event_participants |>
  group_by(Cvr) |>

```

```

summarise(across(everything(), first))    # Første deltagerinfo pr. virksomhed

# -----
# 2.2: Saml alle datasæt med left_join og ryd op i dubletter
# -----

merged_df <- all_companies |>
  left_join(company_contacts, by = "CompanyId") |>    # Join kontaktpersoner
  left_join(all_contact, by = "contactId") |>        # Join kontaktinfo
  left_join(meetings_unique, by = "CompanyId") |>    # Join mødedata
  rename(Cvr = "z_companies_1_CVR-nummer_1") |>      # Omdøber kolonnen til
                                                    # "Cvr", så den matcher med events
  left_join(events_unique, by = "Cvr") |>            # Join eventinfo
  left_join(event_participants_unique, by = "Cvr") |> # Join deltagerinfo
  select(-ends_with(".y"), -ends_with(".x"))        # Fjerner dublet-kolonner

# -----
# 2.3: Klargør datasæt: fjern anonyme oplysninger og omdøb kolonnenavne
# -----

# Fokus: Unikke virksomheder via PNumber (produktionsenhedsnummer)
# Det giver os 2966 unikke observationer.
merged_df <- merged_df |>
  select(-z_companies_1_Firmanavn_1, -z_contacts_1_Email_1)
# Fjerner anonymiserede data

# Standardiser kolonnenavne for overskuelighed
colnames(merged_df) <- c(

```

```

"BusinessCouncilMember", "CompanyDateStamp", "CompanyId", "CompanyType",
"CVR", "Employees", "PostalCode", "CompanyTypeName", "PNumber", "Country",
"NACECode", "CompanyStatus", "AdvertisingProtected", "ContactId",
"CompanyOwnerId", "ContactLastUpdated", "TitleChanged", "LocationChanged",
"CreatedBy", "MeetingLength", "Firstname", "UserRole", "Initials",
"EventExternalId", "EventPublicId", "Description", "LocationId",
"MaxParticipants", "EventLength", "EventId"
)

# -----
# 2.4: Fjern dubletter og irrelevante kolonner
# Udfyld manglende værdier i eventkolonner med "Ingen event"
# -----

# Beholder unikke virksomheder, fjerner irrelevante kolonner,
# og udfylder NA i eventdata
merged_unique <- merged_df |>
  distinct(PNumber, .keep_all = TRUE) |> # Beholder én række pr. PNumber
  select(-TitleChanged, -LocationChanged, -CreatedBy, -Firstname,
    # Fjerner irrelevante variabler
    -UserRole, -Initials, -ContactLastUpdated) |>
  mutate(across( # Erstatte NA i event-kolonner med "Ingen event"
    c(MeetingLength, EventExternalId, EventPublicId, Description,
      LocationId, MaxParticipants, EventLength, EventId),
    ~ if_else(is.na(.), "Ingen event", as.character(.))
  ))

# Rens MeetingLength og konverter til numerisk (fjern " mins")
merged_unique <- merged_unique |>
  mutate(

```

```

MeetingLength = ifelse(MeetingLength == "Ingen event", "0 mins",
                        MeetingLength),
MeetingLength = as.numeric(str_remove(MeetingLength, " mins"))
)

# -----
# 2.5: Splitter NACECode i kode og beskrivelse,
# fjern original kolonne og NA-rækker
# -----

merged_unique <- merged_unique |>
  mutate(
    Employees = if_else(is.na(Employees), "Ukendt", as.character(Employees)),
    # NA -> "Ukendt"

    NACECode = if_else(is.na(NACECode), "Ukendt", as.character(NACECode)),
    # NA -> "Ukendt"

    Nacecode = if_else(NACECode == "Ukendt", "Ukendt",
                        str_extract(NACECode, "[0-9]+")),
    # Hent kode
    Nacebranche = if_else(NACECode == "Ukendt", "Ukendt",
                           str_remove(NACECode, "[0-9]+\\s*")),
    # Hent branche
  ) |>
  select(-NACECode) |> # Fjerner original NACECode-kolonne
  na.omit()           # Fjerner rækker med NA-værdier

# -----
# 2.6: Tjek for tilbageværende NA-værdier
# -----

```

```

# colSums(is.na(merged_unique))

# -----
# 2.7: Gem det rensede datasæt til senere brug
# -----

saveRDS(merged_unique, "merged_unique.rds")

# -----
# 2.8: Merge old_projects (frivillig) med virksomhedsdata
# -----

# Omdøb SMVContactId til ContactId
old_projects <- old_projects |>
  rename(ContactId = SMVContactId) # Omdøb kolonne for at matche join

# Gem kolonnenavne fra old_projects (ekskl. ContactId)
old_project_cols <- setdiff(names(old_projects), "ContactId")
cols_to_fill <- setdiff(old_project_cols, c("Id", "SMVCompanyId", "SharedWith"))

# Join med merged_unique og erstat NA med "Tom"
merged_unique_old_projects <- merged_unique |>
  left_join(old_projects, by = "ContactId") |> # Merger på ContactId
  select(-Id, -SMVCompanyId, -SharedWith) |> # Fjerner unødvendige kolonner
  mutate(across(all_of(cols_to_fill),
    ~ if_else(is.na(.), "Tom", as.character(.)))) |> # NA → "Tom"
  distinct(PNumber, .keep_all = TRUE) # Behold unikke virksomheder

# -----
# 2.9: Tjek for NA-værdier i det udvidede datasæt

```

```

# -----
# colSums(is.na(merged_unique_old_projects))

merge_datasets <- merged_unique_old_projects

# -----

# 3. Cleaning data
# -----

# -----

# 3.1: Første kig på datastrukturen
# Giver et hurtigt overblik over variabelnavne, typer og eksempelverdier
# -----

# glimpse(merge_datasets)

# -----

# 3.2: Tæl hvor mange NA (manglende værdier) der findes i hver kolonne
# Dette er nyttigt for at forstå, hvor der evt. skal renses eller imputeres
# -----

# Tjekker for manglende værdier (NA) i alle variabler
na_count <- merge_datasets |>
  summarise(across(everything(), ~ sum(is.na(.)))) |>
  pivot_longer(everything(), names_to = "variable", values_to = "na_count")

# -----

# 3.3: Rensning af kolonnenavne
# Fjerner forstyrrende elementer som tal, specialtegn og mellemrum
# Gør kolonnenavne nemmere at bruge i videre analyser og modeller
# -----

# Rydder op i variabelnavne: fjerner tal, specialtegn og whitespace

```

```

names(merge_datasets) <- names(merge_datasets) |>
  str_remove("^[0-9]+_1*\\s*") |>      # Fjerner startende tal/1-taller
  str_replace_all("[ /\\-]+", "_") |> # Erstatte mellemrum og specialtegn med _
  str_replace_all("_+", "_") |>      # Fjerner dobbelte underscores
  str_remove("_$") |>                # Fjerner underscore i slutningen
  str_trim()                          # Trim whitespace

# Udskriver de rensede kolonnenavne
# print(names(merge_datasets))

# -----
# 3.4: Fjern irrelevante kolonner (ID'er og tekniske felter)
# Disse kolonner bruges ikke i analysen og fjernes derfor fra datasættet
# -----

clean_data <- merge_datasets |>
  dplyr::select(-ContactId, -CompanyOwnerId, -EventExternalId,
               -EventPublicId, -LocationId, -Tekstfelt, -CompanyType)

# -----
# 3.5: Erstatning og konvertering af værdier
# - Tekst som "Tom", "Ukendt" og "Ingen event" → NA
# - NA i tekstfelter bliver til "Ukendt"
# - NA i tal bliver til 0
# - Udvalgte kolonner konverteres til numerisk format
# -----

clean_data <- clean_data |>
  mutate(
    across(
      c(CVR, Nacecode, PostalCode, PNumber, MaxParticipants,
        EventLength, Employees), ~ as.numeric(ifelse(.x %in% c(" ", "", "Tom",

```



```

                                "Ukendt", "Ingen event"), NA, .x))
),
across(where(is.character), ~ replace_na(.x, "Ukendt")), # Tekst: NA →
# "Ukendt"
across(where(is.numeric), ~ replace_na(.x, 0))           # Tal: NA → 0
)

# -----
# 3.6: Konverter dato-kolonner til rigtig datoformat
# Vigtigt hvis man senere skal beregne fx forskel i tid
# -----
CompanyDateStamp <- as.Date(clean_data$CompanyDateStamp, format = "%Y-%m-%d")
Kontaktdato      <- as.Date(clean_data$Kontaktdato, format = "%Y-%m-%d")

# -----
# 3.7: # Viser datastruktur efter rensning
# -----
# glimpse(clean_data)

# -----
# 4. Feature Engineering
# -----

# -----
# 4.1: # Viser datastruktur efter rensning
# -----

```

```

# glimpse(clean_data) # Bruger glimpse til at få et hurtigt overblik over data

# -----
# 4.2: Opretter en ny variabel, der beregner hvor mange år
# en virksomhed har været medlem. Vi bruger CompanyDateStamp (oprettelsesdato)
# og beregner forskellen til dags dato.
# -----
feature_engineering <- clean_data |>
  mutate(
    medlem_antal_år = round(
      as.numeric(difftime(Sys.Date(), as.Date(CompanyDateStamp),
                          units = "days")) / 365,
      0
    )
  )

# -----
# 4.3: Rensning af Employees-kolonnen (antal ansatte).
# Nogle gange kan tal være formateret med punktummer (f.eks. "1.000")
# eller mellemrum (f.eks. "1 000").
# Disse fjernes, så kolonnen kan konverteres til numerisk format
# -----
feature_engineering <- feature_engineering |>
  mutate(
    Employees = Employees |>
      str_replace_all("\\.", "") |>      # Fjerner punktummer
      str_replace_all("\\s+", "") |>     # Fjerner mellemrum
      as.numeric()                       # Konverterer til tal
  )

```

```

)

# -----
# 4.4: Oversættelse af virksomhedstyper til mere læsbare formater
# Eksempel: "A/S" bliver til "Aktieselskab"
# -----

feature_engineering <- feature_engineering |>
  mutate(
    CompanyTypeName = str_replace_all(CompanyTypeName, "A/S", "Aktieselskab"),
    CompanyTypeName = str_replace_all(CompanyTypeName, "ApS", "Anpartsselskab"),
    CompanyTypeName = str_replace_all(CompanyTypeName, "IVS", "Iværksætterselskab"),
    CompanyTypeName = str_replace_all(CompanyTypeName, "P/S", "Partnerselskab"),
    CompanyTypeName = str_replace_all(CompanyTypeName, "K/S", "Kommanditselskab")
  )

# -----
# 4.5: Tilføj branchebetegnelse baseret på NACE-koder
# NACE er en standard for brancheklassifikation (fx "01 Landbrug")
# Vi bruger de første to cifre til at matche mod en lookup-tabel med branchenavne
# -----

nace_lookup <- read_delim("data/nace_branchenavne.csv", delim = ";") |>
  select(KODE, TITEL) |>
  rename(Nace_kort = KODE, Branche_navn = TITEL)

```

Rows: 1732 Columns: 10

-- Column specification -----

Delimiter: ";"

chr (6): KODE, TITEL, GENERELLE_NOTER, INKLUDERER, INKLUDERER_OGSÅ, EKSKLUDERER

dbl (2): SEKvens, NIVEAU

lg1 (2): PARAGRAF, MÅLEENHED

i Use ``spec()`` to retrieve the full column specification for this data.
i Specify the column types or set ``show_col_types = FALSE`` to quiet this message.

```
# Tilføj branchebetegnelse baseret på Nacecode og fjern overflødige kolonner
# Lav en ny kolonne med de første to cifre af Nacecode
feature_engineering <- feature_engineering |>
  mutate(Nace_kort = substr(Nacecode, 1, 2)) |> # Udtrækker de to første cifre
  select(-Nacebranche) |> # Fjerner den gamle kolonne
  left_join(nace_lookup, by = "Nace_kort") |> # Slår op i brancheregister
  mutate(
    Branche_navn = replace_na(Branche_navn, "Ukendt"),
    # Hvis ingen match, brug "Ukendt"
    Branche_navn = as.factor(Branche_navn)
    # Gør den klar til ML (kategorisk)
  ) |>
  select(-Nacecode, -Nace_kort) |> # Fjerner unødvendige kolonner
  relocate(Branche_navn, .after = PNumber) # Flytter Branche_navn efter PNumber

# -----
# 4.6: Opretter 2. feature/variabel - har virksomheden haft kontakt?
# Vi kigger på flere kolonner og vurderer:
# hvis mindst én ikke er "Tom", så har der været kontakt
# -----

feature_engineering <- feature_engineering |>
  mutate(
    har_haft_kontakt = if_else(
```

```

    Virksomhedsbesøg != "Tom" | Telefonkontakt != "Tom" |
    Konsulent_Navn != "Tom" | Notat != "Tom" | Kontaktdato != "Tom",
    "Ja", "Nej")
  ) |>
select(-Virksomhedsbesøg, -Telefonkontakt, - Konsulent_Navn,
      -Notat, -Kontaktdato)

# -----
# 4.7: Opretter 3. feature/variabel - har virksomheden deltaget i event?
# Hvis EventLength er større end 0, siger vi "Ja", ellers "Nej"
# -----
feature_engineering <- feature_engineering |>
  mutate(deltaget_i_event = if_else(as.numeric(EventLength) > 0, "Ja", "Nej"))

# -----
# 4.8: Skaber kategorier der viser virksomhedens behov for hjælp
# Her grupperes TRUE/FALSE-kolonner i temaer som Strategi, Jura, Økonomi osv.
# Den viser, hvilken overordnet type hjælp virksomheden har modtaget.
# -----
feature_engineering <- feature_engineering |>
  # Sørg for at konvertere kolonnerne til logiske værdier (TRUE/FALSE)
  mutate(across(matches("^\\d+_1"), ~ .x != "FALSE" & .x != "Tom")) |>
  mutate(

# Opretter en enkelt variabel, der kategoriserer virksomheden baseret på de
# 8 områder
  hjælp_kategori = case_when(

```

```

# Hvis virksomheden har søgt hjælp til strategi/emner som
  # forretningsidé, produkt osv.
  (as.logical(Kundeportefølje) | as.logical(Forretningsmodel) |
   as.logical(Forretningsidé) | as.logical(Produktportefølje))
  ~ "Strategi Udvikling",

# Hvis fokus har været på markedsføring, branding eller PR
  (as.logical(Markedsføring) | as.logical(Branding) |
   as.logical(Kommunikation_og_PR)) ~ "Marketing og Kommunikation",

# Hvis der er søgt hjælp til salg, eksport eller markedsposition
  (as.logical(Salg) | as.logical(Eksport) |
   as.logical(Markedsposition)) ~ "Salg og Eksport",

# Hvis der har været fokus på ledelse, netværk eller organisation
  (as.logical(Medarbejdere) | as.logical(Netværk) |
   as.logical(Samarbejdspartnere) | as.logical(Ejer_og_bestyrelse))
  ~ "Organisation og Ledelse",

# Hvis det handler om økonomi, finansiering eller fonde
  (as.logical(Økonomistyring) | as.logical(Finansiering) |
   as.logical(Kapitalfond) | as.logical(Vækstfonden) |
   as.logical(Innovationsfonden)) ~ "Økonomi og Finansiering",

# Hvis det handler om daglig drift, it-systemer eller forretningsgange
  (as.logical(Leverance_og_projektstyring) | as.logical(IT_systemer) |
   as.logical(Faciliteter) |
   as.logical(Forretningsgange)) ~ "Drift og Systemer",

# Hvis fokus er på jura, ejerskifte mv.

```

```

(as.logical(Juridiske_forhold) |
  as.logical(Ejerskifte_og_generationsskifte)) ~ "Jura og Struktur",

# Hvis der er søgt støtte gennem offentlige ordninger
(as.logical(EU_Kontoret_i_DK_Interreg) | as.logical(Erhvervshuset) |
  as.logical(FN_1) |
  as.logical(Andre_nationale_ordninger)) ~ "Støtteordninger",

# Tilføjelse af de nye kategorier
(as.logical(Uddannelse_kompetenceudvikling) |
  as.logical(Vidensordninger) |
  as.logical(IV_Vejledning) |
  as.logical(Virksomhedsbesøg_Virksomhed_under_3_år) |
  as.logical(I_Værkstedet) |
  as.logical(Klippekort_Udleveret) |
  as.logical(Væksthjul_Screening) |
  as.logical(Agro_Business_Park) |
  as.logical(Konsulent_virksomhed uden_for_Kommunen_DK) |
  as.logical(Lokal_konsulent_eller_virksomhed) |
  as.logical(Indenrigsministeriet_The_Trade_Council) |
  as.logical(Produktudviklin)) ~ "Andre Hjælpeordninger",

TRUE ~ "Ingen specifik hjælp"
)
) |>

# Ryd op ved at fjerne de originale variabler der er brugt til grupperingen
select(-c(
  Kundeportefølje, Forretningsmodel, Forretningsidé, Produktportefølje,
  Markedsføring, Branding, Kommunikation_og_PR,
  Salg, Eksport, Markedsposition,

```

```

Medarbejdere, Netværk, Samarbejdspartnere, Ejer_og_bestyrelse,
Økonomistyring, Finansiering, Kapitalfond, Vækstfonden, Innovationsfonden,
Leverance_og_projektstyring, IT_systemer, Faciliteter, Forretningsgange,
Juridiske_forhold, Ejerskifte_og_generationsskifte,
EU_Kontoret_i_DK_Interreg, Erhvervshuset, FN_1, Andre_nationale_ordninger,
Uddannelse_kompetenceudvikling, Vidensordninger, IV_Vejledning,
Virksomhedsbesøg_Virksomhed_under_3_år, I_Værkstedet,
Klippekort_Udleveret, Væksthjul_Screening, Agro_Business_Park,
Konsulent_virksomhed_uden_for_Kommunen_DK, Lokal_konsulent_eller_virksomhed,
Indenrigsministeriet_The_Trade_Council, Produktudviklin
))

# Tjek resultatet
# glimpse(feature_engineering)

# Gemmer PNumber til senere brug (hvis vi kan gøre det, så vi ikke er nødt til
# at have det med videre i modellerne)
# pnumbers <- feature_engineering$PNumber

# -----
# 4.9: Behold kun aktive virksomheder
# -----

feature_engineering <- feature_engineering |>
  filter(CompanyStatus %in% c("Aktiv", "NORMAL")) |>
  dplyr::select(-CompanyDateStamp, -CompanyId, -CVR, -Country,
    -CompanyStatus, -AdvertisingProtected, -MaxParticipants, -Description,
    -EventLength, -EventId, -Andet) # Sletter de kolonner vi ikke vil bruge

# -----
# 4.10: Tilføj churn-kolonne

```



```

# Opretter ny kolonne kaldet 'churn', viser om virksomheden er stoppet som medlem.
# Hvis BusinessCouncilMember er TRUE (virksomheden er medlem), sættes churn = 0
# Hvis BusinessCouncilMember er FALSE (virksomheden har forladt fællesskabet),
# sættes churn = 1
# -----

feature_engineering <- feature_engineering |>
  mutate(churn = if_else(BusinessCouncilMember == TRUE, 0, 1)) |>
  select(-BusinessCouncilMember)

# -----

# 4.11: Konverterer udvalgte kolonner til faktorer,
# som er nødvendigt for ML-modeller
# En faktor er en kategorisk variabel - dvs. den indeholder en begrænset mængde
# unikke værdier (kategorier). # Eksempler på faktorer: postnumre, ja/nej,
# virksomhedsformer (ApS, A/S, IVS osv.)
# I maskinlæring skal sådanne kolonner være faktorer,
# så algoritmerne forstår dem som kategorier og ikke som tekst.
# -----

feature_engineering <- feature_engineering |>
  mutate(
    CompanyTypeName = as.factor(CompanyTypeName),
    har_haft_kontakt = as.factor(har_haft_kontakt),
    deltaget_i_event = as.factor(deltaget_i_event),
    hjælp_kategori = as.factor(hjælp_kategori),
    PostalCode = as.factor(PostalCode),
    churn = as.factor(churn)
  )

# -----

```

```

# 4.12: Gem det færdigbehandlede datasæt til senere analyse eller modellering
# -----
write_rds(feature_engineering, "data/feature_engineered_data.rds")

# Helper-funktion: Henter og opdaterer .rds-filer fra de andre branches

# =====

# 5. Eksplorativ Dataanalyse (EDA)
# =====

#Medlemsstatus

# 5.1 Søjlediagram: Fordeling af medlemsstatus
# 5.2 Boxplot: Medlemsstatus vs. år som medlem
# 5.3 Histogram: Fordeling af medlemsår

#Adfærd

# 5.4 Søjlediagram: Eventdeltagelse blandt aktive medlemmer
# 5.5 Søjlediagram: Kombination af kontakt og eventdeltagelse vs. medlemsstatus
# 5.6 Søjlediagram: Hjælpekategorier blandt aktive deltagere vs. ikke-deltagere

#Baggrundssata: Branche og geografi

# 5.7 Søjlediagram: Branchefordeling blandt aktive medlemmer
# 5.8 Søjlediagram: Eventdeltagelse fordelt på branche
# 5.9 Søjlediagram: Hjælpekategorier fordelt på branche
# 5.10 Søjlediagram: Eventdeltagelse pr. postnummer

#Engagement og korrelationer

# 5.11 Søjlediagram: Gennemsnitlig mødelængde pr. branche
# 5.12 Boxplot: Mødelængde vs. eventdeltagelse

```

```

# 5.13 Boxplot: Mødelængde vs. medlemsstatus
# 5.14 Histogram: Fordeling af mødelængder
# 5.15 Korrelationsmatrix: Numeriske variable

# -----
# Indlæs data
# -----

featured <- feature_engineering

# -----
# Funktion: Identificer outliers med IQR-metoden
# -----
# Vi bruger interkvartil-afstanden (IQR) til at identificere outliers.
# Observationer udenfor [Q1 - 1.5*IQR, Q3 + 1.5*IQR] regnes som outliers.

find_outliers <- function(x) {
  iqr <- IQR(x, na.rm = TRUE)
  lower <- quantile(x, 0.25, na.rm = TRUE) - 1.5 * iqr
  upper <- quantile(x, 0.75, na.rm = TRUE) + 1.5 * iqr
  x < lower | x > upper
}

# -----
# 5.1 Søjlediagram: Fordeling af medlemsstatus
# -----
# En simpel søjlediagram der viser, hvor mange virksomheder der er
# henholdsvis aktive og stoppede.

featured |>
  ggplot(aes(x = factor(churn), fill = factor(churn))) +


```

```

geom_bar() +
geom_text(stat = "count", aes(label = ..count..), vjust = -0.3, size = 5) +
scale_fill_manual(
  values = c("0" = "darkgreen", "1" = "darkred"),
  labels = c("0" = "Aktiv medlem", "1" = "Stoppet medlem"),
  name = "Medlemsstatus"
) +
labs(
  title = "Fordeling af medlemmer hos Business Viborg i øjeblikket",
  x = "Medlemsstatus (0 = medlem, 1 = stoppet)",
  y = "Antal virksomheder"
) +
theme_minimal()

```

Warning: The dot-dot notation (`..count..`) was deprecated in ggplot2 3.4.0.
 i Please use `after_stat(count)` instead.



```

ggsave("images/EDA_1_fordeling_medlemmer.png", width = 7, height = 4, dpi = 300)

# -----
# 5.2 Boxplot: Medlemsstatus vs. år som medlem
# -----
# Vi tjekker hvor længe virksomheder har været medlem afhængigt af medlemsstatus
# og tilføjer info om outliers, gennemsnit og antal.

featured <- featured |>
  mutate(outlier_medlemsår = find_outliers(memlem_antal_år))

nøgletal <- featured |>
  group_by(churn) |>
  summarise(
    antal = n(),
    gennemsnit = round(mean(memlem_antal_år, na.rm = TRUE), 1),
    outliers = sum(outlier_medlemsår, na.rm = TRUE),
    .groups = "drop"
  )


featured |>
  ggplot(aes(x = factor(churn), y = memlem_antal_år, fill = factor(churn))) +
  geom_boxplot(alpha = 0.8, outlier.color = "blue") +
  stat_summary(fun = mean, geom = "point", shape = 18, size = 3, color = "darkred") +
  geom_text(data = nøgletal, aes(x = factor(churn), y = max(featured$memlem_antal_år, na.rm = TRUE),
                                label = paste0("Antal = ", antal)), inherit.aes = FALSE, size = 12) +
  geom_text(data = nøgletal, aes(x = factor(churn), y = gennemsnit,
                                label = paste0("Gns: ", gennemsnit)), inherit.aes = FALSE, color = "darkred", size = 12) +
  geom_text(data = nøgletal, aes(x = factor(churn), y = max(featured$memlem_antal_år, na.rm = TRUE),
                                label = paste0("Outliers: ", outliers)), inherit.aes = FALSE, size = 12)

```

```

scale_fill_manual(
  values = c("0" = "darkgreen", "1" = "darkred"),
  labels = c("0" = "Aktiv medlem", "1" = "Stoppet medlem"),
  name = "Medlemsstatus"
) +
labs(
  title = "Antal år som medlem fordelt på medlemsstatus",
  subtitle = "Rød prik = gennemsnit • Blå prikker = outliers",
  x = "Medlemsstatus",
  y = "År som medlem"
) +
coord_flip() +
theme_minimal()

```



```

ggsave("images/EDA_2_antall_år_medlem.png", width = 7, height = 4, dpi = 300)

```

```
# 5.3 Histogram: Fordeling af medlemsår
```

```
# -----
```

```
# Vi visualiserer fordelingen af hvor længe virksomheder har været medlem.
```

```
# Dette giver et billede af om der er mange nye vs. gamle medlemmer.
```

```
featured |>
```

```
  filter(!is.na(medlem_antal_år)) |>
```

```
  ggplot(aes(x = medlem_antal_år)) +
```

```
  geom_histogram(binwidth = 1, fill = "darkgreen", color = "white", boundary = 0) +
```

```
  labs(
```

```
    title = "Fordeling af antal år som medlem",
```


```
    subtitle = "Histogram med binwidth = 1 år",
```

```
    x = "Antal år som medlem",
```

```
    y = "Antal virksomheder"
```

```
  ) +
```

```
  theme_minimal()
```




```

ggsave("images/EDA_3_fordeling_antal_år.png", width = 7, height = 4, dpi = 300)

# -----
# 5.4 Søjlediagram: Eventdeltagelse blandt aktive medlemmer
# -----
# Visualisering af eventdeltagelse blandt aktive medlemmer
# Her undersøger vi om virksomheder deltager i events, fordelt på 'Ja' og 'Nej'

featured |>
  filter(churn == 0) |>
  ggplot(aes(x = deltaget_i_event, fill = deltaget_i_event)) +
  geom_bar() +
  geom_text(stat = "count", aes(label = ..count..), vjust = -0.3, size = 5) +
  scale_fill_manual(values = c("Ja" = "darkgreen", "Nej" = "grey60")) +
  labs(
    title = "Eventdeltagelse blandt aktive medlemmer",
    x = "Deltaget i event?",
    y = "Antal virksomheder",
    fill = "Eventdeltagelse"
  ) +
  theme_minimal()

```

```
ggsave("images/EDA_4_eventdeltagelse.png", width = 7, height = 4, dpi = 300)

# -----
# 5.5 Søjlediagram: Kombination af kontakt og eventdeltagelse vs. medlemsstatus
# -----

# Vi undersøger, hvordan kombinationen af kontakt og eventdeltagelse
# relaterer sig til medlemsstatus (aktiv eller stoppet).
# Derfor opretter vi en ny variabel "kontakt_event", der grupperer virksomheder
# efter disse kombinationer:
# - Både haft kontakt og deltaget i event
# - Kun haft kontakt
# - Kun deltaget i event
# - Ingen af delene

featured |>
  mutate(
```

```

kontakt_event = case_when(
  har_haft_kontakt == "Ja" & deltaget_i_event == "Ja" ~ "Kontakt & Event",
  har_haft_kontakt == "Ja" & deltaget_i_event == "Nej" ~ "Kun kontakt",
  har_haft_kontakt == "Nej" & deltaget_i_event == "Ja" ~ "Kun event",
  TRUE ~ "Ingen af delene"
)
) |>

# Visualiser fordelingen med søjlediagram, hvor vi stabler medlemsstatus (churn)
ggplot(aes(x = kontakt_event, fill = factor(churn))) +

# geom_bar tæller antallet af observationer i hver kontakt_event-kategori,
# og stabler dem efter medlemsstatus (aktiv = 0, stoppet = 1)
geom_bar(position = "stack") +

# Tilføj antals-labels direkte på søjlerne med hvid tekst
geom_text(stat = "count", aes(label = ..count..),
          position = position_stack(vjust = 0.5), color = "white", size = 4) +

# Definér farver og labels for churn (medlemsstatus)
scale_fill_manual(
  values = c("0" = "darkgreen", "1" = "darkred"), # Grøn for aktiv, rød for stoppet
  labels = c("0" = "Aktiv", "1" = "Stoppet"),
  name = "Medlemsstatus"
) +

# Tilføj titler og akse-labels
labs(
  title = "Kombination af kontakt og eventdeltagelse",
  subtitle = "Fordelt på medlemsstatus",
  x = "Kategorier af kontakt og event",

```


```

y = "Antal virksomheder"
) +

# Brug minimalistisk tema
theme_minimal() +

# Drej x-aksens tekst lidt for bedre læsbarhed
theme(axis.text.x = element_text(angle = 20, hjust = 1))

```



```

ggsave("images/EDA_5_kombination_kontakt_event.png", width = 7, height = 4, dpi = 300)

# -----
# 5.6 Søjlediagram: Hjælpekategori blandt aktive deltagere vs. ikke deltagere
# -----
# Vi undersøger hvilke typer hjælp virksomheder har fået.
# Det opdeles i to grupper:
# - Aktive medlemmer, der IKKE har deltaget i events


```

```

# - Aktive medlemmer, der HAR deltaget i events
# På den måde kan vi sammenligne hvilke behov de to grupper har.

# Ikke-deltagere i event - hvilke typer hjælp efterspørger de?
# -----
featured |>
  filter(churn == 0, deltaget_i_event == "Nej") |>           # Kun aktive, ikke-deltagere
  count(hjælp_kategori, name = "antal") |>                 # Tæl antal pr. hjælpekategori
  filter(!is.na(hjælp_kategori)) |>                         # Fjern NA
  ggplot(aes(x = fct_reorder(hjælp_kategori, antal), y = antal)) +
  geom_col(fill = "darkred") +                               # Farve: Rød for ikke-deltagere
  geom_text(aes(label = antal), hjust = -0.1, size = 4) +
  coord_flip() +                                             # Vandret søjlediagram
  labs(
    title = "Hjælpetyper hos aktive medlemmer der ikke deltager i events",
    subtitle = "Viser hvilke behov de har uden deltagelse i events",
    x = "Hjælpekategori",
    y = "Antal virksomheder"
  ) +
  theme_minimal()

```




```
ggsave("images/EDA_6_deltager_ikke_events.png", width = 7, height = 4, dpi = 300)

# Deltagere i event - hvilke typer hjælp efterspørger de?
# -----

featured |>
  filter(churn == 0, deltaget_i_event == "Ja") |>           # Kun aktive, deltagere
  count(hjælp_kategori, name = "antal") |>
  filter(!is.na(hjælp_kategori)) |>
  ggplot(aes(x = fct_reorder(hjælp_kategori, antal), y = antal)) +
  geom_col(fill = "darkgreen") +                             # Farve: grøn for deltagere
  geom_text(aes(label = antal), hjust = -0.1, size = 4) +
  coord_flip() +
  labs(
    title = "Hjælpetyper hos aktive medlemmer der deltager i events",
    subtitle = "Viser hvilke behov de har, trods deltagelse i events",
    x = "Hjælpekategori",
    y = "Antal virksomheder"
```

```
) +  
theme_minimal()
```



```
ggsave("images/EDA_6_1_deltager_i_events.png", width = 7, height = 4, dpi = 300)
```

```
# -----  
# 5.7 Søjlediagram: Branchefordeling blandt aktive medlemmer  
# -----
```

```
# Vi undersøger hvilke brancher de *aktive* virksomheder (medlemmer) tilhører.  
# Formålet er at få et overblik over, hvilke brancher der er mest repræsenteret  
# blandt dem, der stadig er med i fællesskabet (churn == 0).  
# Kun brancher med mindst 10 virksomheder vises, for at sikre et læsbart plot.
```

```
featured |>
```

```
# Filtrér: medtag kun virksomheder der stadig er medlemmer (aktive)
```

```
filter(churn == 0) |>
```

```

# Tæl antallet af virksomheder pr. branche
count(Branche_navn, name = "antal") |>

# Fjern brancher med færre end 10 aktive virksomheder
filter(antal >= 10) |>

# Sortér brancherne efter antal, så de vises i rigtig rækkefølge i plottet
mutate(Branche_navn = fct_reorder(Branche_navn, antal)) |>

# Visualiser fordelingen med søjlediagram
ggplot(aes(x = Branche_navn, y = antal)) +

# geom_col bruger vores forudberegnete 'antal' til at tegne søjler
geom_col(fill = "darkgreen") +

# Tilføj antals-labels til søjlerne (antal virksomheder)
geom_text(aes(label = antal), hjust = -0.1, size = 4) +

# Vend koordinaterne, så brancherne vises lodret og er nemmere at læse
coord_flip() +

# Tilføj titel, undertitel og aksetekster
labs(
  title = "Branchefordeling blandt aktive medlemmer",
  subtitle = "Viser kun brancher med mindst 10 aktive virksomheder",
  x = "Branche",
  y = "Antal virksomheder"
) +

# Brug minimalistisk tema for et rent visuelt udtryk

```

```
theme_minimal()
```

```
Engroshandel undtagen med motorkøretøjer og motorcykle  
Bygge- og anlægsvirksomhed, som kræver specialiserin  
Hovedsæders virksomhed; virksomhedsrådgivnin  
Pengeinstitut- og finansieringsvirksomhed undtagen forsikring o  
Arkitekt- og ingeniørvirksomhed; teknisk afprøvning og analys  
Detailhandel undtagen med motorkøretøjer og motorcykle  
Undervisnin  
Fast ejendor  
Juridisk bistand, bogføring og revisio  
Reklame og markedsanalys  
Computerprogrammering, konsulentbistand vedrørende informationsteknologi og lignende aktivitete  
Andre liberale, videnskabelige og tekniske tjenesteydelse  
Jern- og metalvareindustri, undtagen maskiner og udsty  
Sundhedsvæse  
Sport, forlystelser og fritidsaktivitete  
Fremstilling af maskiner og udstyr i.a.r  
Organisationer og foreninge  
Administrationsservice, kontorservice og anden forretnings servic
```

Antal vi

```
ggsave("images/EDA_7_branchefordeling.png", width = 7, height = 4, dpi = 300)
```

```
# -----
```

```
# 5.8 Søjlediagram: Eventdeltagelse fordelt på branche (kun aktive medlemmer)
```

```
# -----
```

```
# Vi undersøger hvordan virksomhedernes deltagelse i events varierer
```

```
# på tværs af brancher.
```

```
# Kun aktive virksomheder (churn == 0) tages med i analysen.
```

```
# Vi vil gerne se, hvor mange fra hver branche der har deltaget /
```

```
# ikke deltaget i events.
```

```
brancher_antal <- featured |>
```

```
# Filtrér: medtag kun aktive virksomheder
```

```
filter(churn == 0) |>
```



```

# Tæl antallet af virksomheder for hver kombination af branche og eventdeltagelse
count(Branche_navn, deltaget_i_event, name = "antal") |>

# Beregn totalen pr. branche (summen af 'Ja' og 'Nej')
group_by(Branche_navn) |>
mutate(total = sum(antal)) |>

# Behold kun brancher med mindst 10 aktive virksomheder i alt
filter(total >= 10) |>
ungroup()

# Sortér brancher efter hvor mange virksomheder der har deltaget i events ("Ja")
sortering <- brancher_antal |>
  filter(deltaget_i_event == "Ja") |>
  arrange(desc(antal)) |>
  pull(Branche_navn)

brancher_antal |>
  # Sortér brancherne i plottet ud fra antallet af 'Ja'-svar
  mutate(Branche_navn = factor(Branche_navn, levels = unique(sortering))) |>

  # Opret stacked søjlediagram, hvor 'Ja' og 'Nej' ligger oven på hinanden
  ggplot(aes(x = Branche_navn, y = antal, fill = deltaget_i_event)) +

  # geom_col tegner søjlerne baseret på vores antal
  geom_col(position = "stack") +

  # Tilføj tekstetiketter med antal, centreret i hver del af søjlen
  geom_text(aes(label = antal), position = position_stack(vjust = 0.5),
            color = "white", size = 4) +

```

```

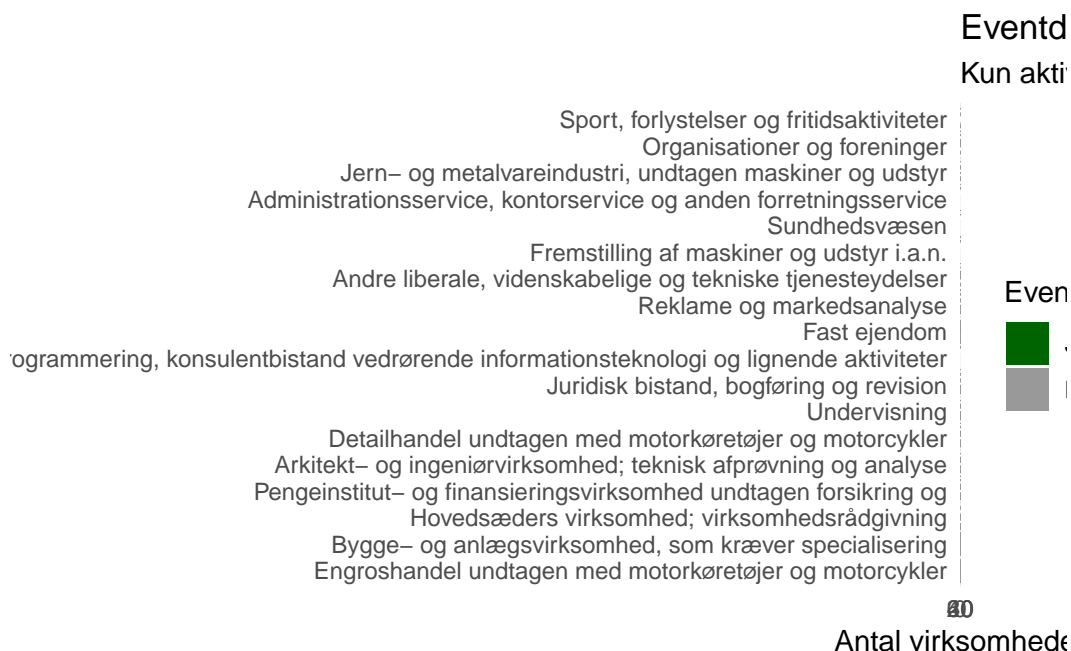
# Vend akserne, så brancherne læses nemmere
coord_flip() +

# Brug manuelle farver: grøn = deltaget, grå = ikke deltaget
scale_fill_manual(values = c("Ja" = "darkgreen", "Nej" = "grey60")) +

# Tilføj titler og akse-labels
labs(
  title = "Eventdeltagelse fordelt på branche",
  subtitle = "Kun aktive medlemmer med min. 10 virksomheder per branche",
  x = "Branche",
  y = "Antal virksomheder",
  fill = "Eventdeltagelse"
) +

# Brug minimalistisk ggplot-tema
theme_minimal()

```



```
ggsave("images/EDA_8_eventdeltagelse_branche.png", width = 7, height = 4, dpi = 300)

# -----
# 5.9 Søjlediagram: Hjælpekategorier fordelt på branche (kun aktive medlemmer)
# -----

# Vi ønsker at undersøge, hvilke typer hjælp aktive virksomheder efterspørger,
# og hvordan det varierer på tværs af brancher.
# Fokus er på aktive medlemmer (churn == 0), og vi ser kun på brancher
# med mindst 5 registrerede hjælpetilfælde, for at sikre relevans i plottet.

featured |>
  # Filtrér: medtag kun aktive virksomheder og fjern rækker uden hjælpekategori
  filter(churn == 0, !is.na(hjælp_kategori)) |>

  # Tæl antallet af hjælperegistreringer pr. branche og hjælpekategori
  count(Branche_navn, hjælp_kategori, name = "antal") |>
```

```

# Beregn total antal hjælperegistreringer pr. branche
group_by(Branche_navn) |>
mutate(total = sum(antal)) |>
ungroup() |>

# Fjern brancher med under 5 hjælperegistreringer
filter(total >= 5) |>

# Sortér brancherne efter total, så de vises i rigtig rækkefølge i plottet
mutate(Branche_navn = fct_reorder(Branche_navn, total)) |>

# Opret søjlediagram med hjælpekategori som fill (farvelag)
ggplot(aes(x = Branche_navn, y = antal, fill = hjælp_kategori)) +

# geom_col tegner de stablede søjler (én farve pr. hjælpekategori)
geom_col() +

# Vend koordinatsystemet, så brancherne er på y-aksen (bedre læsbarhed)
coord_flip() +

# Tilføj titler og aksetekster
labs(
  title = "Hjælpekategorier fordelt på branche",
  subtitle = "Kun aktive medlemmer med mindst 5 registrerede hjælpetilfælde",
  x = "Branche",
  y = "Antal hjælperegistreringer",
  fill = "Hjælpekategori"
) +

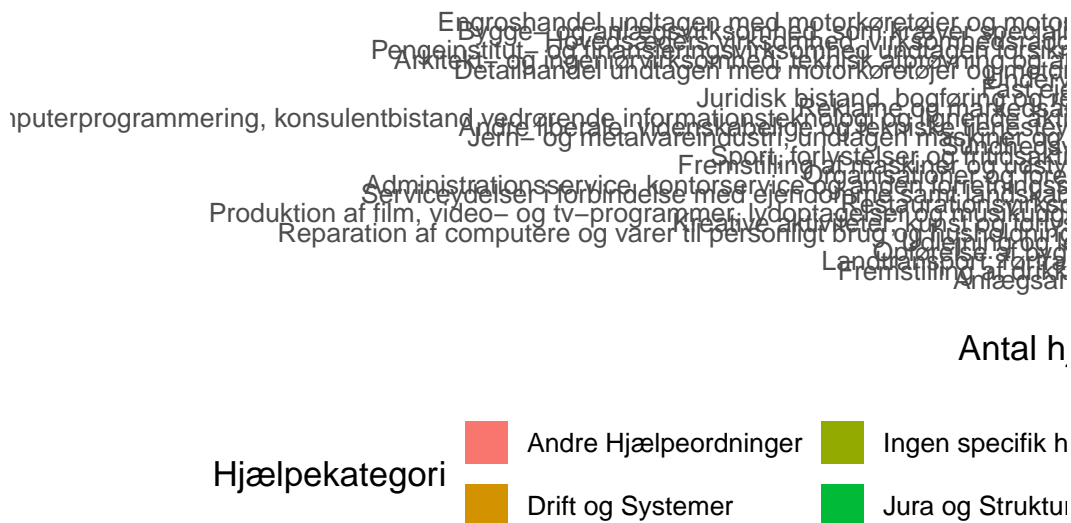
# Brug minimalistisk ggplot-tema og lidt større tekst

```

```
theme_minimal(base_size = 13) +

# Flyt legenden ned under plottet (bedre ved mange kategorier)

theme(legend.position = "bottom")
```



```
ggsave("images/EDA_9_hjælpe kategorier_branche.png", width = 7, height = 4, dpi = 300)

# -----
# 5.10 Søjlediagram: Eventdeltagelse pr. postnummer (Aktive medlemmer)
# -----

# Vi undersøger, hvordan aktive virksomheders eventdeltagelse fordeler sig geografisk,
# baseret på postnummer. Vi viser både deltagelse ("Ja") og ikke-deltagelse ("Nej"),
# og sorterer postnumrene efter hvor stor andelen af 'Ja'-svar er.

# Beregn antal og andel for hver kombination af postnummer og eventdeltagelse
post_event <- featured |>
```

```

# Filtrér: medtag kun aktive virksomheder
filter(churn == 0) |>

# Tæl antallet af virksomheder pr. postnummer og eventstatus
count(PostalCode, deltaget_i_event, name = "antal") |>

# Beregn total antal og procentuel andel inden for hvert postnummer
group_by(PostalCode) |>
mutate(
  total = sum(antal),          # Total antal virksomheder
  andel = round(antal / total * 100, 1) # Andel i procent
) |>
ungroup()

# Sortér postnumre efter andel af virksomheder der har deltaget i events ("Ja")
post_order <- post_event |>
  filter(deltaget_i_event == "Ja") |>
  arrange(desc(andel)) |>
  pull(PostalCode)

# Visualiser data som stacked søjlediagram
post_event |>
  # Sortér postnumrene i plottet efter andel 'Ja'
  mutate(PostalCode = factor(PostalCode, levels = post_order)) |>

  # Opret plot med antal virksomheder pr. postnummer, farvet efter eventdeltagelse
  ggplot(aes(x = PostalCode, y = antal, fill = deltaget_i_event)) +

  # geom_col tegner stablede søjler
  geom_col() +

```

```

# Tilføj antalslabels midt i søjlerne
geom_text(aes(label = antal), position = position_stack(vjust = 0.5),
          color = "white", size = 3.5) +


# Brug manuelle farver: grøn = deltager, grå = deltager ikke
scale_fill_manual(values = c("Ja" = "darkgreen", "Nej" = "grey60")) +

# Vend koordinatsystemet for bedre læsbarhed
coord_flip() +

# Tilføj titel, aksetitler og farveforklaring
labs(
  title = "Eventdeltagelse pr. postnummer (aktive virksomheder)",
  subtitle = "Sorteret efter postnumre med flest 'Ja'-svar",
  x = "Postnummer",
  y = "Antal virksomheder",
  fill = "Eventdeltagelse"
) +

# Brug minimalistisk ggplot-tema
theme_minimal()

```



```
ggsave("images/EDA_10_eventdeltagelse_postnummer.png", width = 7, height = 4, dpi = 300)
```

```
# -----
# 5.11 Søjlediagram: Gennemsnitlig mødelængde pr. branche (kun aktive medlemmer)
# -----
```

```
# Vi undersøger hvor lang tid møderne i gennemsnit varer for hver branche,
# men ser kun på aktive medlemmer og brancher med tilstrækkeligt datagrundlag.
# Det giver indsigt i, hvilke brancher der fx kræver mere sparring eller støtte.
```

```
featured |>
```

```
# Filtrér: medtag kun aktive medlemmer med gyldig mødelængde (> 0 og ikke NA)
```

```
filter(churn == 0, !is.na(MeetingLength), MeetingLength > 0) |>
```

```
# Beregn gennemsnitlig mødelængde og antal møder pr. branche
```

```
group_by(Branche_navn) |>
```

```
summarise(
```



```

    gennemsnit_min = round(mean(MeetingLength, na.rm = TRUE), 1), # afrundet gennemsnit
    antal = n(), # antal møder
    .groups = "drop"
) |>

# Behold kun brancher med mindst 5 registrerede møder
filter(antal >= 1) |>

# Sortér brancherne efter gennemsnitlig mødelængde (fra højest til lavest)
arrange(desc(gennemsnit_min)) |>

# Reordn faktorniveauerne så sorteringen overføres til plot
mutate(Branche_navn = fct_reorder(Branche_navn, gennemsnit_min)) |>

# Visualiser data med et søjlediagram
ggplot(aes(x = Branche_navn, y = gennemsnit_min)) +

# geom_col viser gennemsnitlig mødelængde pr. branche
geom_col(fill = "darkgreen", alpha = 0.8) +

# Tilføj tekstetiketter med mødelængden på hver søjle
geom_text(aes(label = paste0(gennemsnit_min, " min")), hjust = -0.1, size = 4) +

# Vend koordinaterne så brancherne vises lodret og er nemmere at læse
coord_flip() +

# Tilføj titler, undertitel og akse-labels
labs(
  title = "Gennemsnitlig mødelængde pr. branche (aktive medlemmer)",
  subtitle = "Viser kun brancher med mindst 5 registrerede møder",

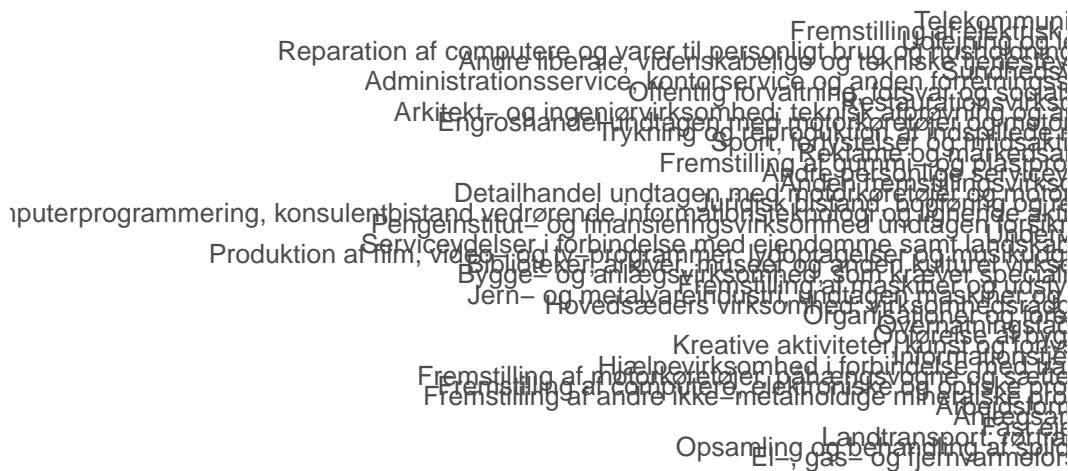
```

```

x = "Branche",
y = "Gennemsnitlig mødelængde (minutter)"
) +

# Brug minimalistisk ggplot-tema og lidt større base-tekst
theme_minimal(base_size = 13)

```



Gennemsnitlig mødelængde

```

ggsave("images/EDA_11_mødelængde.png", width = 7, height = 4, dpi = 300)

# -----
# 5.12 Boxplot: Mødelængde vs. eventdeltagelse (kun aktive medlemmer)
# -----

# Vi undersøger, om der er forskel i mødelængde blandt aktive virksomheder
# afhængigt af om de har deltaget i events eller ej.
# Vi visualiserer forskellen med boxplots og markerer både gennemsnit og outliers.

```

```

# Gør datasættet klar: filtrér aktive, beregn outliers, og opret grupper
meeting_event <- featured |>

# Filtrér kun aktive virksomheder med mødelængde registreret
filter(churn == 0, !is.na(MeetingLength)) |>

# Opret en ny variabel "Eventgruppe" baseret på om de har deltaget i events
mutate(
  Eventgruppe = if_else(deltaget_i_event == "Ja", "Deltager i event", "Deltager ikke"),

  # Identificer outliers i mødelængde med IQR-metoden
  outlier = find_outliers(MeetingLength)
)

# Udtræk statistik til annotationer i boxplottet
meeting_stats <- meeting_event |>
  group_by(Eventgruppe) |>
  summarise(
    antal = n(), # Antal observationer pr. gruppe
    gennemsnit = round(mean(MeetingLength), 1), # Gennemsnitlig mødelængde
    outliers = sum(outlier), # Antal outliers
    .groups = "drop"
  )

# Visualisér forskellen med boxplots
meeting_event |>
  ggplot(aes(x = Eventgruppe, y = MeetingLength, fill = Eventgruppe)) +

  # Boxplot viser fordeling, median og outliers
  geom_boxplot(alpha = 0.7, outlier.color = "blue") +

```

```

# Tilføj en rød prik for gennemsnittet i hver gruppe
stat_summary(fun = mean, geom = "point", shape = 18, size = 3, color = "darkred") +

# Annotér med antal virksomheder pr. gruppe (øverst over boxplot)
geom_text(data = meeting_stats, aes(x = Eventgruppe,
                                     y = max(meeting_event$MeetingLength, na.rm = TRUE) + 5,
                                     label = paste0("n = ", antal)), size = 4) +

# Annotér med gennemsnitlig mødelængde
geom_text(data = meeting_stats, aes(x = Eventgruppe, y = gennemsnit,
                                     label = paste0("Gns: ", gennemsnit, " min")),
          size = 4, color = "darkred", nudge_y = 5) +

# Vend koordinatsystemet, så grupperne vises lodret
coord_flip() +

# Brug manuelle farver til at skelne mellem deltager/ikke-deltager
scale_fill_manual(values = c("Deltager i event" = "darkgreen", "Deltager ikke" = "red")) +

# Tilføj titler, aksetitel og undertekst
labs(
  title = "Mødelængde vs. eventdeltagelse (aktive medlemmer)",
  subtitle = "Rød prik = gennemsnit • Blå prikker = outliers",
  x = NULL, # Ingen x-aksenavn (grupperne forklarer sig selv)
  y = "Mødelængde (minutter)"
) +

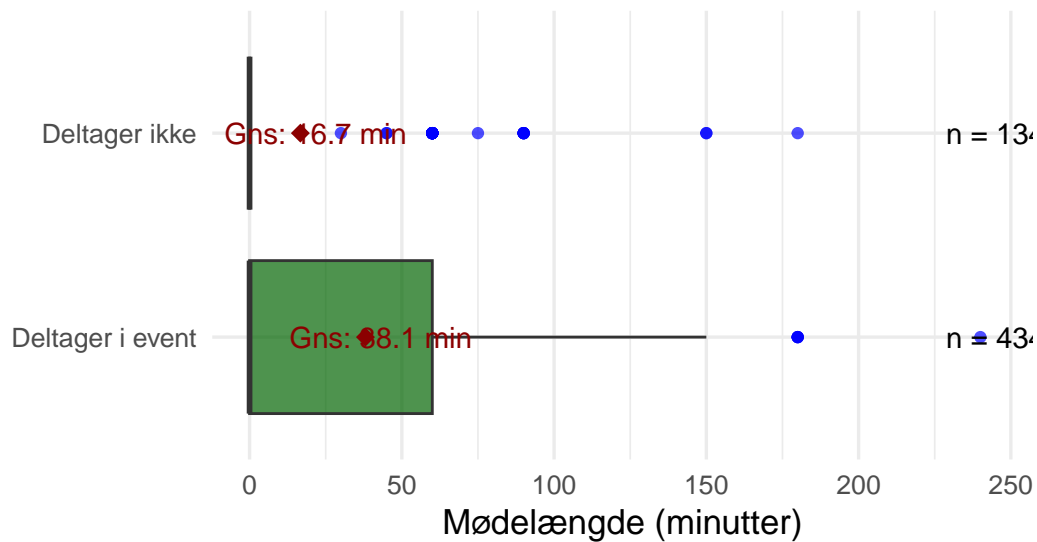
# Brug minimalistisk tema med større font
theme_minimal(base_size = 13) +

```

```
# Fjern legend, da den ikke er nødvendig - informationen er allerede tydelig i x-aksen
theme(legend.position = "none")
```

Mødelængde vs. eventdeltagelse (aktive med)

Rød prik = gennemsnit . Blå prikker = outliers



```
ggsave("images/EDA_12_mødelængde_eventdeltagelse.png", width = 7, height = 4, dpi = 300)
```

```
# -----
# 5.13 Boxplot: Mødelængde vs. medlemsstatus
# -----

# Vi undersøger, om der er forskel i mødelængde mellem aktive og stoppede medlemmer.
# Dette kan give indsigt i, om engagement (målt som mødetid) har betydning for churn.

# Udregn nøgleoplysninger til visning i plottet
meeting_churn_stats <- featured |>
  filter(!is.na(MeetingLength)) |>
  group_by(churn) |>
  summarise(
```

```

    n = n(), # Antal observationer
    gennemsnit = round(mean(MeetingLength, na.rm = TRUE), 1), # Gennemsnitlig mødelængde
    outliers = sum(find_outliers(MeetingLength)), # Antal outliers
    .groups = "drop"
  ) |>
  mutate(churn = factor(churn, levels = c(0, 1), labels = c("Aktiv", "Stoppet")))

# Opret boxplot med medlemsstatus som grupperingsvariabel
featured |>
  filter(!is.na(MeetingLength)) |>
  mutate(
    churn = factor(churn, levels = c(0, 1), labels = c("Aktiv", "Stoppet")),
    outlier = find_outliers(MeetingLength)
  ) |>
  ggplot(aes(x = churn, y = MeetingLength, fill = churn)) +

  # Vis fordeling og outliers som boxplot
  geom_boxplot(alpha = 0.7, outlier.shape = 16, outlier.color = "blue", outlier.size = 2) +

  # Marker gennemsnittet med en rød prik
  stat_summary(fun = mean, geom = "point", color = "darkred", size = 3, shape = 18) +

  # Tilføj tekst med gennemsnitlig mødelængde for hver gruppe
  geom_text(data = meeting_churn_stats, aes(x = churn, y = gennemsnit,
                                             label = paste0("Gns: ", gennemsnit, " min")),
            color = "darkred", size = 4, nudge_y = 5, inherit.aes = FALSE) +

  # Vis antal observationer som tekst over hver boks
  geom_text(data = meeting_churn_stats, aes(x = churn, y = max(featured$MeetingLength, na.rm = TRUE),
                                             label = paste0("n = ", n)),

```

```

    color = "black", size = 4, inherit.aes = FALSE) +

# Vend akserne, så medlemsstatus vises lodret
coord_flip() +

# Brug farver der skelner aktiv og stoppet medlemsstatus
scale_fill_manual(values = c("Aktiv" = "darkgreen", "Stoppet" = "darkred")) +


# Tilføj titler og aksetekster
labs(
  title = "Mødelængde vs. medlemsstatus",
  subtitle = "Rød prik = gennemsnit • Blå prikker = outliers",
  x = "Medlemsstatus",
  y = "Mødelængde (minutter)",
  fill = "Status"
) +

# Brug minimalistisk tema og fjern legend
theme_minimal(base_size = 13) +
theme(legend.position = "none")

```

Mødelængde vs. medlemsstatus

Rød prik = gennemsnit . Blå prikker = outliers



```
ggsave("images/EDA_13_mødelængde_medlemsstatus.png", width = 7, height = 4, dpi = 300)
```

```
# -----  
# 5.14 Histogram: Fordeling af mødelængder  
# -----
```

```
# Vi undersøger hvordan mødelængder fordeler sig blandt aktive medlemmer,  
# for at se om der er typiske længder, outliers eller skævhed.
```


```
featured |>  
  filter(churn == 0, !is.na(MeetingLength), MeetingLength > 0) |>  
  ggplot(aes(x = MeetingLength)) +  
  geom_histogram(binwidth = 10, fill = "darkgreen", color = "white", boundary = 0) +  
  labs(  
    title = "Fordeling af mødelængder (aktive medlemmer)",  
    subtitle = "Histogram med binwidth = 10 minutter",  
    x = "Mødelængde (minutter)",
```



```

y = "Antal møder"
) +
theme_minimal()

```



```

ggsave("images/EDA_14_fordeling_mødelængder.png", width = 7, height = 4, dpi = 300)

# -----
# 5.15 Korrelationsmatrix: Numeriske variable
# -----

# Vi ønsker at undersøge, hvordan de numeriske variable i datasættet hænger sammen.
# Det gør vi ved at udtrække alle numeriske kolonner og beregne en korrelationsmatrix.
# Denne visualiseres som et cirkelplot med Pearson-korrelationer.

# Udtræk kun de kolonner i datasættet, der er numeriske
featured_numerisk <- featured |>
  select(where(is.numeric)) |>

```

```

# Fjern rækker med NA-værdier, da korrelationsberegning kræver komplette værdier
drop_na()

# Beregn korrelationsmatrix ved hjælp af Pearson's metode
cor_matrix <- cor(featured_numerisk, use = "pairwise.complete.obs")

# Afrund korrelationerne til 2 decimaler for pænere visning (valgfrit trin)
cor_matrix_rounded <- round(cor_matrix, 2)

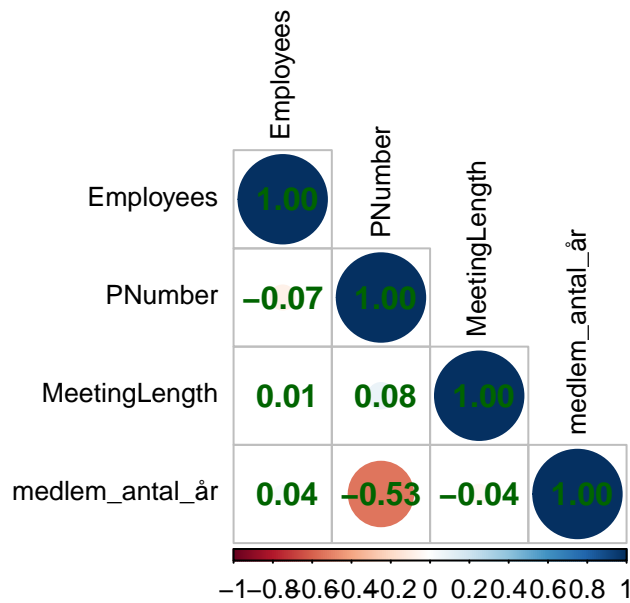
# Visualisér korrelationerne med et "cirkelplot" fra pakken 'corrplot'
corrplot::corrplot(
  cor_matrix,

  method = "circle",      # Brug cirkler til at vise styrke og retning af korrelation
  type = "lower",         # Vis kun nederste trekant (mere overskueligt)

  # Tekst og talindstillinger
  tl.cex = 0.8,           # Størrelse på tekstetiketter (variabelnavne)
  tl.col = "black",       # Farve på variabelnavne

  addCoef.col = "darkgreen" # Vis selve korrelationstallet inde i cirklerne
)

```



```
ggsave("images/EDA_15_korrelationsmatrix.png", width = 7, height = 4, dpi = 300)
```

```
# -----
# 6. Preprocessing
# -----

set.seed(2025)

churn_split <- initial_split(feature_engineering, prop = 0.8, strata = churn)
churn_train <- training(churn_split)
churn_test  <- testing(churn_split)

churn_folds <- vfold_cv(churn_train, v = 10, strata = churn)

churn_recipe <-
  recipe(churn ~ ., data = churn_train) |>
  step_novel(all_nominal_predictors()) |>
  step_dummy(all_nominal_predictors(), one_hot = TRUE) |>
```

```

step_zv(all_predictors()) |>
step_normalize(all_numeric_predictors()) |>
step_downsample(churn) # Brug evt. step_smote(churn) hvis ekstrem ubalance

```

```

# -----
# 7. Modelling
# -----

# Model specs
rf_spec <- rand_forest(mtry = tune(), min_n = tune()) |>
  set_engine("ranger", importance = "impurity") |>
  set_mode("classification")

xgb_spec <- boost_tree(trees = tune(), mtry = tune(), learn_rate = tune()) |>
  set_engine("xgboost") |>
  set_mode("classification")

log_reg_spec <- logistic_reg(penalty = tune(), mixture = tune()) |>
  set_engine("glmnet") |>
  set_mode("classification")

knn_spec <- nearest_neighbor(neighbors = tune(), weight_func = tune()) |>
  set_engine("kknn") |>
  set_mode("classification")

nb_spec <- naive_Bayes(smoothness = tune(), Laplace = tune()) |>
  set_engine("naivebayes") |>
  set_mode("classification")

svm_spec <- svm_rbf(cost = tune(), rbf_sigma = tune()) |>

```

```

set_engine("kernlab") |>
set_mode("classification")

# Samlet workflow set
churn_workflow_set <- workflow_set(
  preproc = list(churn_recipe = churn_recipe),
  models = list(
    rf = rf_spec,
    xgboost = xgb_spec,
    logistic = log_reg_spec,
    knn = knn_spec,
    naive_bayes = nb_spec,
    svm_rbf = svm_spec
  )
)

```

```

# -----
# 8. Evaluate metrics
# -----

churn_metrics <- metric_set(accuracy, roc_auc, f_meas, sens, spec)

grid_ctrl <- control_grid(
  verbose = TRUE,
  save_pred = TRUE,
  parallel_over = "everything",
  save_workflow = TRUE
)

plan(multisession)
strt.time <- Sys.time()

```

```
# Vi kører modellerne - den står og arbejder
churn_results <- churn_workflow_set |>
  workflow_map(
    resamples = churn_folds,
    grid = 5,
    metrics = churn_metrics,
    control = grid_ctrl,
    seed = 2025
  )
```

```
Sys.time() - strt.time
```

Time difference of 1.843477 mins

```
plan(sequential)

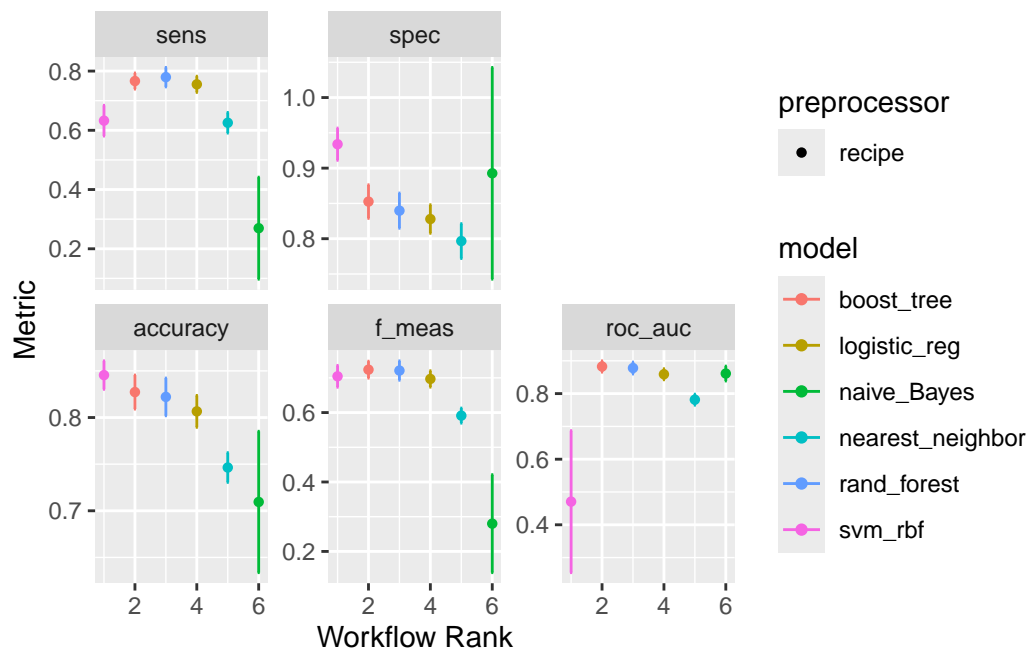
# Sammenlign resultater
churn_results |>
  rank_results(select_best = TRUE) |>
  select(wflow_id, .metric, mean) |>
  pivot_wider(names_from = .metric, values_from = mean) |>
  arrange(-f_meas)
```

A tibble: 6 x 6

	wflow_id	accuracy	f_meas	roc_auc	sens	spec
	<chr>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	churn_recipe_xgboost	0.827	0.724	0.883	0.766	0.853
2	churn_recipe_rf	0.822	0.721	0.878	0.779	0.840
3	churn_recipe_svm_rbf	0.846	0.704	0.471	0.633	0.934
4	churn_recipe_logistic	0.807	0.697	0.859	0.755	0.828
5	churn_recipe_knn	0.746	0.591	0.781	0.625	0.797

```
6 churn_recipe_naive_bayes    0.709  0.280    0.861 0.270 0.893
```

```
autoplot(churn_results, select_best = TRUE)
```



```
# -----
# 9. Visualisering
# -----
# Plot modeller efter deres performance
# -----

# Din tibble, hvis ikke du allerede har den i en variabel:
metrics_df <- tibble::tibble(
  wflow_id = c("churn_recipe_rf", "churn_recipe_xgboost", "churn_recipe_svm_rbf",
               "churn_recipe_logistic", "churn_recipe_knn", "churn_recipe_naive_bayes"),
  accuracy = c(0.825, 0.827, 0.845, 0.807, 0.743, 0.710),
  f_meas   = c(0.724, 0.723, 0.708, 0.697, 0.592, 0.287),
  roc_auc  = c(0.877, 0.881, 0.439, 0.858, 0.778, 0.855),
```

```

sens      = c(0.777, 0.766, 0.643, 0.755, 0.634, 0.272),
spec      = c(0.845, 0.852, 0.929, 0.828, 0.788, 0.893)
)

# Pivot til langt format
metrics_long <- metrics_df %>%
  pivot_longer(cols = -wflow_id, names_to = "metric", values_to = "score")

# Gør labels lidt pænere
metrics_focus <- metrics_long %>%
  filter(metric %in% c("accuracy", "f_meas", "roc_auc")) %>%
  mutate(metric = case_when(
    metric == "accuracy" ~ "Accuracy",
    metric == "f_meas" ~ "F1-score",
    metric == "roc_auc" ~ "ROC AUC",
    TRUE ~ metric
  ))

# Nr. 1: BarPlot med værdier for denne 3 metrikker

ggplot(metrics_focus, aes(x = metric, y = score, fill = metric)) +
  geom_col(show.legend = FALSE) +
  geom_text(aes(label = round(score, 2)), vjust = -0.3, size = 3.5) +
  facet_wrap(~ wflow_id) +
  ylim(0, 1.05) +
  labs(
    title = "Model performance (Accuracy, F1 og ROC AUC)",
    x = NULL,
    y = "Score"
  ) +


```



```

theme_minimal() +
theme(
  axis.text.x = element_text(angle = 0),
  plot.title = element_text(hjust = 0.5, size = 14, face = "bold")
) +
scale_fill_brewer(palette = "Set3")

```



```

ggsave("images/1_model_performance.png", width = 7, height = 4, dpi = 300)

```

Nr. 2: Linje plot

```

ggplot(metrics_focus, aes(x = wflow_id, y = score, color = metric, group = metric)) +
  geom_line(size = 1) +
  geom_point(size = 3) +
  geom_text(aes(label = round(score, 2)), vjust = -0.7, size = 3) +
  scale_color_brewer(palette = "Dark2") +
  labs(


```

```

    title = "Sammenligning på tværs af modeller",
    x = "Model",
    y = "Score"
  ) +
  theme_minimal() +
  theme(
    axis.text.x = element_text(angle = 45, hjust = 1),
    plot.title = element_text(hjust = 0.5)
  )

```

Warning: Using `size` aesthetic for lines was deprecated in ggplot2 3.4.0.
 i Please use `linewidth` instead.



```

ggsave("images/2_linje_plot.png", width = 7, height = 4, dpi = 300)


```

```

# Nr. 3: Heatmap pr. model og metrik

```

```
ggplot(metrics_focus, aes(x = metric, y = wflow_id, fill = score)) +
  geom_tile(color = "white") +
  geom_text(aes(label = round(score, 2)), size = 3) +
  scale_fill_gradient(low = "white", high = "steelblue") +
  labs(
    title = "Performance heatmap pr. model og metrik",
    x = "Metric",
    y = "Model"
  ) +
  theme_minimal() +
  theme(plot.title = element_text(hjust = 0.5))
```



```
ggsave("images/3_heatmap_pr_model.png", width = 7, height = 4, dpi = 300)
```

```
# -----
# Plot for xgboost og Random forest med de vigtigste variabler
# -----
```

```

# Hent tuning-resultater for rf og xgboost
rf_result <- churn_results %>% extract_workflow_set_result("churn_recipe_rf")
xgb_result <- churn_results %>% extract_workflow_set_result("churn_recipe_xgboost")

# Hent workflow (før det er fit)
rf_workflow <- churn_results %>% extract_workflow("churn_recipe_rf")
xgb_workflow <- churn_results %>% extract_workflow("churn_recipe_xgboost")

# Vælg bedste parametre og fit modellen
best_rf <- rf_workflow %>%
  finalize_workflow(select_best(rf_result, metric = "f_meas")) %>%
  fit(data = churn_train)

best_xgb <- xgb_workflow %>%
  finalize_workflow(select_best(xgb_result, metric = "f_meas")) %>%
  fit(data = churn_train)

# Feature importance
vip_rf <- vi(extract_fit_parsnip(best_rf)) %>% mutate(model = "Random Forest")
vip_xgb <- vi(extract_fit_parsnip(best_xgb)) %>% mutate(model = "XGBoost")

# Kombinér og vis kun top 10 vigtigste variabler pr. model
vip_combined <- bind_rows(vip_rf, vip_xgb) %>%
  group_by(model) %>%
  slice_max(order_by = Importance, n = 10) %>%
  ungroup() %>%
  mutate(Variable = str_wrap(Variable, width = 25))

# Plot med labels og tekstrotation optimeret
ggplot(vip_combined, aes(x = reorder(Variable, Importance), y = Importance, fill = model)) +

```

```

geom_col(show.legend = FALSE) +
geom_text(aes(label = round(Importance, 2)), hjust = -0.1, size = 3) +
facet_wrap(~ model, scales = "free") +
coord_flip() +
labs(
  title = "Top 10 vigtigste variabler pr. model",
  x = "Variabel",
  y = "Vigtighed"
) +
theme_minimal() +
theme(
  plot.title = element_text(hjust = 0.5, size = 14, face = "bold"),
  strip.text = element_text(size = 12, face = "bold"),
  axis.text.y = element_text(size = 9)
) +
scale_y_continuous(expand = expansion(mult = c(0, 0.10))) #ekstra space til labels

```

Top 10 vigtigste variabler pr. mo



```
ggsave("images/4_top_10_variabler_pr_model.png", width = 7, height = 4, dpi = 300)
# -----
```

```
# -----
# 10. Endelig model - Finetuning af Random Forest
# -----
```

```
# undersøg kun på hele datasæt
```

```
# 1. Lav et workflow set med kun én model: Random Forest
```

```
churn_workflow_set_rf <- workflow_set(
  preproc = list(churn_recipe = churn_recipe),
  models  = list(rf = rf_spec) # kun én model
)
```

```
# 2. Tænd for parallelisering
```

```
plan(multisession)
```

```
# 3. Start tidstagnig
```

```
strt.time <- Sys.time()
```

```
# 4. Tuning af kun Random Forest med 25 kombinationer
```

```
churn_results_rf <- churn_workflow_set_rf |> # <-- her var der fejl i dit input
  workflow_map(
    resamples = churn_folds,
    grid = 25,
    metrics = churn_metrics,
    control = grid_ctrl,
    seed = 2025
  )
```

```
# 5. Tid brugt
```

```
Sys.time() - strt.time
```

Time difference of 1.824688 mins

```
# 6. Sluk for parallelisering
```

```
plan(sequential)
```

```
# 7. Vis bedste resultater pr. metrik
```

```
churn_results_rf |>
```

```
  rank_results(select_best = TRUE) |>
```

```
  select(wflow_id, .metric, mean) |>
```

```
  pivot_wider(names_from = .metric, values_from = mean) |>
```


```
  arrange(-f_meas)
```

```
# A tibble: 1 x 6
```

wflow_id	accuracy	f_meas	roc_auc	sens	spec
<chr>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1 churn_recipe_rf	0.825	0.724	0.892	0.782	0.843

```
# 8. Visualisér den bedste model
```

```
autoplot(churn_results_rf, select_best = TRUE)
```



```
# -----
# 11. Evaluering af bedste model på testdatasættet (Random Forest)
# -----

# Bemærk: Modellen i dette afsnit er baseret på finetuning med 25 kombinationer

# 1. Find bedste parametre for den bedste model
best_results <- churn_results_rf |>
  extract_workflow_set_result("churn_recipe_rf") |>
  select_best(metric = "f_meas")

# 2. Finaliser workflow med de fundne parametre
final_wf <- churn_results_rf |>
  extract_workflow("churn_recipe_rf") |>
  finalize_workflow(best_results)

# 3. Træn modellen på træningsdata og evaluer på testdata
```



```
churn_last_fit <- final_wf |>
  last_fit(split = churn_split, metrics = churn_metrics)

# 4. Udskriv evalueringsmetrikker
collect_metrics(churn_last_fit)
```

```
# A tibble: 5 x 4
  .metric .estimator .estimate .config
  <chr>    <chr>        <dbl> <chr>
1 accuracy binary      0.871 Preprocessor1_Model1
2 f_meas  binary      0.8   Preprocessor1_Model1
3 sens    binary      0.877 Preprocessor1_Model1
4 spec    binary      0.868 Preprocessor1_Model1
5 roc_auc binary      0.938 Preprocessor1_Model1
```

```
# 5. Gem confusion matrix som objekt (brugbar til præsentation)
conf_matrix <- churn_last_fit |>
  collect_predictions() |>
  conf_mat(estimate = .pred_class, truth = churn)
```

```
# 6. Gem test-prædiktioner hvis ønsket
test_preds <- collect_predictions(churn_last_fit)
```

```
# 7. Træn endelig model på hele datasættet
final_model <- fit(final_wf, data = feature_engineering)
```

```
# 8. Gem modellen
saveRDS(final_model, "final_churn_model.rds")
```

```
# -----
```

```
# 11.1 Eksempel: Forudsig churn for én ny virksomhed
# -----

new_company <- tibble(
  Employees = 15,
  PostalCode = factor("8800"),
  CompanyTypeName = factor("Aktieselskab"),
  har_haft_kontakt = factor("Ja"),
  deltaget_i_event = factor("Nej"),
  hjælp_kategori = factor("Strategi Udvikling"),
  medlem_antal_år = 2,
  Branche_navn = factor("Fremstilling af maskiner og udstyr i.a.n."),
  MeetingLength = 180,
  PNumber = 12345678
)

# Forudsiger klassifikation og sandsynlighed
predict(final_model, new_company) # 0 = bliver, 1 = churn
```

```
# A tibble: 1 x 1
  .pred_class
  <fct>
1 0
```

```
predict(final_model, new_company, type = "prob") # churn-sandsynlighed
```

```
# A tibble: 1 x 2
  .pred_0 .pred_1
  <dbl>   <dbl>
1 0.633 0.367
```

```

# -----
# 11.2 Forudsig churn for ALLE virksomheder og tilføj resultater
# -----

# Modellen anvendes nu på hele medlemsdatabasen for at identificere churn-risiko

# Forudsiger sandsynlighed og klasse
churn_probs <- predict(final_model, feature_engineering, type = "prob")
churn_classes <- predict(final_model, feature_engineering)

# Kombiner og omdøb kolonner
all_predictions <- bind_cols(churn_probs, churn_classes) |>
  rename(
    churn_prob = .pred_1,      # Sandsynlighed for churn
    churn_class = .pred_class # Klassifikation (0/1)
  )

# Tilføj til datasættet og konvertér sandsynlighed til procent
full_results <- feature_engineering |>
  bind_cols(all_predictions) |>
  mutate(
    churn_prob = round(churn_prob * 100, 1)
  )

# Tilføj churn-risikokategorier tidligt (bruges i visualiseringer og rapporter)
full_results <- full_results |>
  mutate(
    churn_risiko = case_when(
      churn_prob >= 80 ~ "Høj risiko",
      churn_prob >= 60 ~ "Moderat risiko",

```

```

    churn_prob >= 40 ~ "Lav risiko",
    TRUE          ~ "Minimal risiko"
  )
)


# -----
# 11.3 Visualisering: Fordeling af churn-risikokategorier (kun aktive medlemmer)
# -----

full_results |>
  filter(churn == 0) |>
  count(churn_risiko) |>
  ggplot(aes(x = reorder(churn_risiko, -n), y = n, fill = churn_risiko)) +
  geom_col(show.legend = FALSE) +
  geom_text(aes(label = n), vjust = -1, size = 5) +
  scale_fill_manual(values = c(
    "Minimal risiko" = "darkgreen",
    "Lav risiko"     = "green4",
    "Moderat risiko" = "orange",
    "Høj risiko"     = "darkred"
  )) +
  scale_y_continuous(expand = expansion(mult = c(0, 0.1))) +
  coord_cartesian(clip = "off") +
  labs(
    title = "Fordeling af churn-risiko blandt aktive medlemmer",
    subtitle = "Kategorier: Minimal (<40%), Lav (40-59.9%), Moderat (60-79.9%), Høj (80-100%)",
    x = "Risikokategori",
    y = "Antal virksomheder"
  ) +
  theme_minimal()

```

Fordeling af churn-risiko blandt aktive medlemmer

Kategorier: Minimal (<40%), Lav (40–59.9%), Moderat (60–79.9%), Høj (≥80%)



```
ggsave("images/9_churn_risikokategorier_aktive.png", width = 7, height = 4, dpi = 300)
```


```
# -----  
# 11.4 Churn-risiko: Filtrér medlemmer (churn == 0) med høj risiko (churn_class == 1)  
# -----
```

```
top_risiko_medlemmer <- full_results |>  
  filter(churn == 0, churn_class == 1) |>  
  arrange(desc(churn_prob)) |>  
  slice_head(n = 20) # Call to action: top 20
```

```
# -----  
# 11.5 Visualiseringer: Brancher og postnumre med høj churn  
# -----
```

```
# Brancher med højest gennemsnitlig churn  
full_results |>
```

```
group_by(Branche_navn) |>
summarise(gennemsnitlig_churn = mean(churn_prob), n = n()) |>
arrange(desc(gennemsnitlig_churn)) |>
slice_head(n = 5) |>
ggplot(aes(x = reorder(Branche_navn, gennemsnitlig_churn), y = gennemsnitlig_churn)) +
geom_col(fill = "steelblue") +
coord_flip() +
labs(title = "Top 5 churn-risiko", x = "Branche", y = "Gns. churn sandsynlighed (%)") +
theme_minimal()
```




```
ggsave("images/5_brancher_højeste_churn.png", width = 7, height = 4, dpi = 300)

# Postnumre med højest gennemsnitlig churn
full_results |>
group_by(PostalCode) |>
summarise(gennemsnitlig_churn = mean(churn_prob), n = n()) |>
arrange(desc(gennemsnitlig_churn)) |>
```

```

slice_head(n = 5) |>
ggplot(aes(x = reorder(as.character(PostalCode), gennemsnitlig_churn), y = gennemsnitlig_churn))
geom_col(fill = "darkred") +
coord_flip() +
labs(title = "Top 5 postnumre med højest churn-risiko", x = "Postnummer", y = "Gns. churn sandsynlighed (%)")
theme_minimal()

```



```

ggsave("images/6_postnummer_højeste_churn.png", width = 7, height = 4, dpi = 300)

```

```

# -----
# 11.6 Hvad kendetegner virksomheder der IKKE cherner?
# -----

```

```


full_results |>
  filter(churn_class == 0) |> # Virksomheder som modellen forudser bliver
  count(Branche_navn, sort = TRUE) |>
  slice_head(n = 5) |>

```

```

ggplot(aes(x = reorder(Branche_navn, n), y = n)) +
  geom_col(fill = "forestgreen") +
  coord_flip() +
  labs(
    title = "Top 5 der ikke churner",
    x = "Branche",
    y = "Antal virksomheder"
  ) +
  theme_minimal()

```



```

ggsave("images/7_top5_der_ikke_churner.png", width = 7, height = 4, dpi = 300)

# Sammenlignende statistik på udvalgte variabler
# churn_class:
# 0 = modellen tror de bliver
# 1 = modellen tror de churner
full_results |>

```



```
group_by(churn_class) |>
summarise(
  mødelængde = mean(MeetingLength),
  medlem_år = mean(medlem_antal_år),
  kontakt_rate = mean(har_haft_kontakt == "Ja"),
  event_rate = mean(deltaget_i_event == "Ja")
)
```

A tibble: 2 x 5

	churn_class	mødelængde	medlem_år	kontakt_rate	event_rate
	<fct>	<dbl>	<dbl>	<dbl>	<dbl>
1	0	31.8	8.19	0.569	0.861
2	1	3.53	7.69	0.240	0.0252

```
# -----
# 11.7 Hvad er de vigtigste parametre
# -----
```

1. Udtræk tuning-resultater og workflow

```
rf_result <- churn_results_rf |> extract_workflow_set_result("churn_recipe_rf")
rf_workflow <- churn_results_rf |> extract_workflow("churn_recipe_rf")
```


2. Find bedste parametre og træn modellen på træningsdata

```
best_rf <- rf_workflow |>
  finalize_workflow(select_best(rf_result, metric = "f_meas")) |>
  fit(data = churn_train)
```

3. Brug vip til at finde top 10 vigtigste variabler

```
vip_rf <- vi(extract_fit_parsnip(best_rf)) |>
  slice_max(order_by = Importance, n = 10) |>
  mutate(Variable = str_wrap(Variable, width = 30))
```

```
# 4. Plot
ggplot(vip_rf, aes(x = reorder(Variable, Importance), y = Importance)) +
  geom_col(fill = "steelblue") +
  coord_flip() +
  labs(
    title = "Top 10 variabler (RF)",
    x = "Variabel",
    y = "Vigtighed"
  ) +
  theme_minimal() +
  theme(
    plot.title = element_text(hjust = 0.5, size = 14, face = "bold"),
    axis.text.y = element_text(size = 10)
  )
)
```



```

# 5. Gem billedet
ggsave("images/8_top_10_variabler_rf.png", width = 7, height = 4, dpi = 300)

# Gemmer full_results som RDS
saveRDS(full_results, "full_results.rds")

# -----
# Forklaring af churn-relaterede variabler
# -----

# 1. churn:
#   Den faktiske status for virksomheden ifølge databasen.
#   0 = Virksomheden er stadig medlem.
#   1 = Virksomheden har meldt sig ud (churnet).
#   Dette er det "rigtige facit", vi forsøger at forudsige.

# 2. .pred_0:
#   Modellens vurdering af sandsynligheden for, at virksomheden IKKE cherner.
#   Fx 0.93 betyder: modellen mener der er 93 % chance for, at virksomheden bliver medlem.
#   OBS: Denne bruges mest til teknisk forståelse - i praksis bruger vi oftest churn_prob i stedet.

# 3. churn_prob:
#   Modellens vurdering af sandsynligheden for churn - konverteret til procent.
#   Fx 6.1 betyder: modellen vurderer, at der er 6,1 % risiko for, at virksomheden cherner.
#   Denne kolonne er lettest at forstå og bruge i praksis.

# 4. churn_class:
#   Modellens endelige beslutning: churn eller ej?
#   1 = modellen tror virksomheden cherner
#   0 = modellen tror virksomheden bliver

```

```
#   Beslutningen bygger på en tærskel, typisk 50 %

# 5. churn_risiko:
#   Kategori baseret på churn_prob - lavet for at gøre det endnu mere overskueligt.
#   Fx:
#       • "Minimal risiko" → under 40 %
#       • "Lav risiko"      → 40-59 %
#       • "Moderat risiko" → 60-79 %
#       • "Høj risiko"     → 80 % eller højere
```